PENGELOMPOKAN SAMPAH ELEKTRONIK TANPA LABEL DARI CITRA MULTISUMBER DENGAN CROSS-MODEL RESIDUAL ERASURE DAN SPECTRAL CLUSTERING

Studi Kasus Pemilahan Sampah Spesifik di Indonesia

PENGELOMPOKAN SAMPAH ELEKTRONIK TANPA LABEL DARI CITRA MULTISUMBER DENGAN CROSS-MODEL RESIDUAL ERASURE DAN SPECTRAL CLUSTERING

Studi Kasus Pemilahan Sampah Spesifik di Indonesia

Abstrak

Foto sampah elektronik dari sumber berbeda dapat tampak lebih mirip menurut latar dan resolusinya daripada menurut jenis perangkatnya. Penelitian ini menguji persoalan tersebut pada 3.792 citra utama BDC dengan embedding SigLIP2, Perception Encoder, dan DINOv3. Cross-Model Residual Erasure (CMRE) mengurangi arah dominan pada residu embedding model visi-bahasa yang tidak terprediksi dari DINOv3, tanpa memakai label objek atau proksi gaya. Jumlah kelompok dipilih dengan SCMax, partisi dibentuk melalui Spectral clustering, dan citra di luar kelompok yang dikenal ditandai memakai jarak tetangga terdekat. Pada data pengembangan, konsistensi lintas sumber naik dari 0,524 menjadi 0,975; Adjusted Mutual Information (AMI) partisi akhir pada 2.329 citra BDC berlabel mencapai 0,917. Selisih terhadap INLP yang memerlukan proksi gaya tidak signifikan pada uji ini. Audit 100 seed SCMax mempertahankan median K = 16, tetapi hanya 20 seed memilih tepat 16 dan 27 seed memilih K sedikitnya 18. Pada set Iliev dengan protokol terkunci, konsistensi mencapai 0,885 dibanding 0,803 tanpa CMRE; pada set konfirmasi Shubha yang lebih kecil, nilainya 0,956 dibanding 0,356. Enam belas kelompok akhir memisahkan beberapa subtipe baterai, perangkat berlayar, dan mesin cuci. Deteksi kategori baru mencapai AUROC 0,994 pada Shubha, tetapi uji tersebut hanya mencakup dua kelas di luar kategori. Temuan ini menunjukkan bahwa pengurangan bias sumber membantu pengelompokan lintas foto, sedangkan ketahanan pada foto rumah tangga Indonesia masih perlu diuji.

Kata kunci: sampah elektronik; pengelompokan tanpa label; bias sumber foto; representasi visual; deteksi kategori baru

1. PENDAHULUAN

Dunia menghasilkan 62 juta ton sampah elektronik pada 2022. Dari jumlah itu, 22,3% tercatat dikumpulkan dan didaur ulang secara layak (Baldé et al., 2024). Di

Indonesia, timbulan pada 2021 diperkirakan sekitar 2 juta ton, sementara bagian yang dikelola dengan baik baru 17,4% (Defitri, 2022). Angka tersebut menjadikan pemilahan awal penting: perangkat yang tampak serupa dapat memerlukan penanganan berbeda.

Aki dan kaca tabung CRT mengandung timbal; baterai litium dapat terbakar ketika rusak; beberapa lampu serta layar lama mengandung merkuri. Peraturan Pemerintah Nomor 27 Tahun 2020 mengatur sampah yang mengandung bahan berbahaya dan beracun sebagai sampah spesifik (Pemerintah Republik Indonesia, 2020). Karena itu, salah mengenali perangkat pada tahap pemilahan dapat berdampak pada keselamatan pembongkaran dan pilihan jalur pengolahan.

Foto dapat membantu petugas atau warga mengenali jenis perangkat sebelum memilahnya. Akan tetapi, citra produk, foto objek dengan latar beragam, dan foto lapangan memiliki ciri akuisisi yang berbeda. Model yang belajar dari kemiripan visual mungkin mengikuti perbedaan tersebut, bukan identitas perangkat. Pelabelan manual seluruh citra mahal, sedangkan kategori yang ditentukan sejak awal dapat melewatkan subtipe penting. Penelitian ini menilai apakah pengelompokan tanpa label dapat mengurangi kedua kendala itu.

Penelitian terdahulu memberi titik banding yang berbeda (Tabel 1). Gundupalli et al. (2018) memilah fraksi material melalui citra termal, tetapi memerlukan kamera khusus. Islam et al. (2023) serta Rajeev et al. (2025) memperoleh hasil klasifikasi dan deteksi yang baik untuk kelas yang telah ditetapkan, dengan kebutuhan label saat pelatihan. YODO menelusuri laptop di lini pembongkaran tanpa label (Zhou et al., 2023). DECMCV mengelompokkan sampah umum tanpa label dan mencatat gangguan akibat perbedaan gaya foto, tetapi menyisihkan citra yang tidak disepakati antarmetode (Huang et al., 2025). Dengan demikian, hasil pada satu sumber atau satu jenis perangkat belum menjawab apakah kelompok bertahan ketika objek yang sama difoto dengan cara berbeda.

Tabel 1. Ringkasan penelitian terdahulu

Studi	Data dan metode	Hasil (metrik)	Kelebihan	Keterbatasan
Gundupalli et al. (2018)	Citra termal LWIR; fitur intensitas; 4 fraksi material	Akurasi 84-96%	Memilah material langsung di lini daur ulang	Butuh kamera termal; bukan foto biasa
Islam et al. (2023), EWasteNet	8 jenis perangkat; transformer DeiT dua aliran (terawasi)	Akurasi 96%	Akurasi tinggi pada 8 jenis perangkat	Butuh label; kategori tetap; satu sumber data

Studi	Data dan metode	Hasil (metrik)	Kelebihan	Keterbatasan
Rajeev et al. (2025)	700 citra, 7 jenis komponen; YOLOv5/v7/v8	YOLOv8: presisi 0,832; mAP50 0,821	Melokalisasi komponen, bukan hanya mengklasifikasi	Terawasi; skala komponen; data kecil
Zhou et al. (2023), YODO	Penelusuran WEEE tanpa label di lini pembongkaran	Retrieval laptop tanpa label	Tanpa label; terhubung ke proses pembongkaran	Satu jenis produk; lingkungan terkendali
Huang et al. (2025), DECMCV	Sampah umum; ConvNeXt + ViT kontrastif; voting multi-clustering	Akurasi 93,78% (TrashNet)	Tanpa label; menyadari masalah gaya foto	Membuang data yang tidak disepakati; bias gaya belum diukur

1.1 Rumusan masalah

Masalah penelitian dirumuskan dalam empat pertanyaan. Pertama, apakah representasi visual lebih dipengaruhi sumber foto daripada jenis perangkat? Kedua, dapatkah pengaruh tersebut dikurangi tanpa label atau proksi gaya? Ketiga, apakah kelompok yang terbentuk cukup stabil dan dapat ditafsirkan setelah jumlah kelompok dipilih tanpa label? Keempat, apakah foto dari sumber lain dan perangkat di luar kategori dapat ditangani tanpa membentuk ulang kelompok?

1.2 Tujuan dan batasan penelitian

Untuk menjawabnya, penelitian ini memakai citra utama BDC untuk menemukan kelompok, lalu menilai hasilnya pada data eksternal dengan representasi dan partisi yang dibekukan. Label nama berkas hanya dipakai setelah pengelompokan untuk menafsirkan hasil; pemetaan ke kategori WEEE juga dilakukan setelah kelompok terbentuk. CMRE diusulkan sebagai modifikasi proyeksi residu antarmodel: embedding model visi-bahasa diprediksi dari DINOv3, kemudian arah dominan pada bagian yang tidak terprediksi diproyeksikan keluar. SCMax memilih jumlah kelompok, Spectral clustering membentuk partisi, dan skor tetangga terdekat menandai citra yang belum terwakili. Kontribusi yang diuji ialah pengukuran bias sumber, pengurangan bias tanpa proksi, serta evaluasi lintas sumber dan kategori baru. Hasilnya dimaksudkan sebagai dasar penelitian pemilahan berbasis foto, belum sebagai sistem siap pakai.

2. METODOLOGI

2.1 Data dan pemisahan peran dataset

Data utama berasal dari 3.961 citra e-waste BDC. Deduplikasi perceptual hash dengan batas jarak Hamming 6 menyisakan 3.604 citra latih unik. Sebanyak 188 citra uji penyisihan ditambahkan memakai prediksi pengklasifikasi SigLIP2 dari babak sebelumnya, tanpa label panitia, sehingga data utama berisi 3.792 citra. Sebagai pemeriksaan, seluruh pipeline dijalankan kembali hanya pada 3.604 citra latih: xsrc tetap 0,975 dan kesesuaian partisi dengan hasil utama mencapai ARI 0,93 pada citra latih. Nama berkas menyediakan label objek yang valid bagi 2.329 citra dalam sepuluh kelas. Dua entri bernama upload dikeluarkan dari evaluasi kelas, sedangkan 1.461 citra tidak memiliki label nama berkas. Label tidak dipakai untuk ekstraksi fitur, pemilihan K, atau pembentukan cluster.

Tujuh set data publik tambahan memiliki peran evaluasi yang berbeda (Tabel 2). Citra eksternal diproyeksikan ke kelompok yang telah dibentuk dari data utama; tidak ada pelatihan ulang atau pengelompokan ulang. Duplikat terhadap BDC dibuang dengan perceptual hash. Audit menemukan 55% citra Kaan beririsan dengan BDC sebelum pembersihan, sehingga langkah ini diperlukan untuk mencegah kebocoran evaluasi. Protokol serta pemetaan kelas Iliev dan Shubha ditetapkan sebelum data diunduh. Sebaliknya, xsrc BDC dipakai untuk membandingkan lebih dari 40 varian metode; nilainya harus dibaca sebagai hasil pengembangan, bukan estimasi generalisasi independen. Office-Home digunakan hanya untuk pengujian sesuai lisensi riset nonkomersial.

Tabel 2. Sumber data yang digunakan

Sumber	Jumlah	Jenis foto	Peran	Lisensi
BDC (latih + uji penyisihan)	3.792	citra campuran	data utama (clustering)	panitia
Kaan, Waste Classification (Kaggle)	1.794	citra produk	evaluasi objek	CDLA-Permissive-1.0
Custom Bangladeshi E-Waste (Mendeley)	480	foto objek	evaluasi lintas sumber	CC BY 4.0
Garbage Classification, baterai (Kaggle)	499	web	evaluasi objek	Apache 2.0
GIZ E-Waste Database (Hugging Face)	1.000	foto lapangan	uji OOD lapangan	CC BY 4.0
E-Waste Dataset, Iliev (Roboflow)	1.751 (69 kelas)	campuran	uji terkunci	CC BY 4.0

Sumber	Jumlah	Jenis foto	Peran	Lisensi
E-waste, Shubha (Roboflow)	300 (3 kelas dikenal + 2 OOD)	campuran	uji segar	CC BY 4.0
Office-Home (Venkateswara et al., 2017)	2.917 (20 kelas)	Product vs Real World	uji domain lain	riset non-komersial

Pemeriksaan awal memperlihatkan perbedaan antarsumber yang besar. Sebanyak 66% citra BDC berukuran paling tinggi 200 piksel, dan citra produk Kaan juga banyak berupa gambar kecil berlatar putih. Foto objek Bangladesh umumnya sekitar 640 piksel dengan latar beragam, sedangkan foto lapangan GIZ mendekati 1.000 piksel. Perbedaan resolusi dan latar pada objek yang sama menjadi alasan untuk menguji konsistensi lintas sumber, bukan hanya kemurnian kelompok pada BDC.

2.2 Landasan metode

SigLIP2 dan Perception Encoder memakai pelatihan visi-bahasa yang menghubungkan citra dengan teks (Tschannen et al., 2025; Bolya et al., 2025). DINOv3 mempelajari representasi visual tanpa pasangan teks (Siméoni et al., 2025). Penelitian ini hanya menggunakan menara citra dari ketiga model. Perbedaan cara pelatihan tersebut penting karena informasi semantik dan ciri sumber foto dapat muncul dengan bobot berbeda pada embedding masing-masing model.

Ciri resolusi, latar, atau pencahayaan dapat menjadi jalan pintas bagi model ketika berkorelasi dengan kelas pada data latih (Geirhos et al., 2020). HEX menekan statistik superfisial melalui representasi pembantu dan proyeksi (Wang et al., 2019); UMFC mengalibrasi fitur CLIP lintas domain tanpa label (Liang et al., 2024). INLP dan LEACE menghapus arah atribut yang telah ditentukan melalui label atau proksi (Ravfogel et al., 2020; Belrose et al., 2023). CMRE mengambil gagasan proyeksi residu, tetapi menggunakan prediktabilitas antarmodel sebagai dasar memilih arah yang dibuang, sehingga tidak memerlukan definisi gaya foto di muka.

Spectral clustering mempartisi graf tetangga terdekat melalui vektor eigen Laplacian (Ng et al., 2002). SCMax memilih jumlah kelompok dari konsistensi tingkat penggabungan antara representasi asli dan representasi yang diperturbasi (Zhang et al., 2026). Keduanya menjalankan tugas berbeda: SCMax menghasilkan K, sedangkan Spectral clustering membentuk partisi akhir. Untuk citra baru, jarak ke tetangga terdekat pada data utama dipakai sebagai skor deteksi di luar distribusi (Sun et al., 2022).

2.3 Rancangan metode

Alur penelitian terdiri atas deduplikasi dan ekstraksi embedding, pengurangan arah residu dengan CMRE, fusi fitur, pemilihan K oleh SCMax, partisi Spectral, serta evaluasi kelompok dan deteksi kategori baru. Semua keputusan pembentukan kelompok memakai citra dan embedding data utama; label objek baru dibuka pada tahap evaluasi.

Citra dideduplikasi, diubah ukurannya sesuai model, lalu diproses dalam orientasi asli dan cerminan horizontal; kedua embedding dirata-rata. SigLIP2-So400m dan PE-Core-G dipilih sebagai model visi-bahasa, sedangkan DINOv3-H+ menjadi acuan visual tanpa supervisi bahasa. Pada setiap model visi-bahasa, regresi ridge memprediksi embedding V dari embedding DINOv3 S. Residu R menampung bagian V yang tidak terprediksi (Persamaan 1). PCA pada R menghasilkan arah dominan U_r (Persamaan 2), lalu proyeksi pada Persamaan 3 mengeluarkan arah itu dari V. Arah residu tidak diasumsikan seluruhnya sebagai gaya foto; sebagian informasi objek mungkin ikut terbuang. Karena itu, pengaruh CMRE dinilai dengan metrik objek dan lintas sumber.

$$(\hat{B}, \hat{b}) = \underset{B,b}{\operatorname{argmin}} \|V - SB - \mathbf{1}b^{\top}\|_F^2 + \alpha\|B\|_F^2 \tag{1}$$

$$R = V - S\hat{B} - \mathbf{1}\hat{b}^{\top}, \qquad U_r = \mathrm{PCA}_r(R) \tag{2}$$

$$\tilde{v} = \frac{(I - U_r U_r^{\top})v}{\|(I - U_r U_r^{\top})v\|_2} \tag{3}$$

Banyaknya arah yang dihapus ditentukan tanpa label dari 50% varians residu, dengan batas 64 komponen; pada data ini r mencapai batas tersebut. Parameter ridge memakai nilai baku α = 1. DINOv3-H+ dipilih sebagai acuan karena prediksi silang embedding VLM-nya tinggi di antara model SSL yang dapat dijalankan: R^2 ridge 0,403, dibanding 0,434 pada DINOv3-7B yang memerlukan GPU A100. Kedua embedding visi-bahasa hasil CMRE digabung dengan DINOv3, direduksi menjadi 32 dimensi melalui PCA, kemudian dinormalisasi (Persamaan 4). Istilah erasure dalam CMRE merujuk pada proyeksi arah residu, bukan klaim bahwa identitas sumber telah hilang dari embedding.

$$z = \mathrm{PCA}_{32}\left(\left[\tilde{v}_{\mathrm{SigLIP2}};\ \tilde{v}_{\mathrm{PE}};\ s_{\mathrm{DINOv3}}\right]\right) \tag{4}$$

SCMax mula-mula dijalankan pada embedding hasil fusi dengan sembilan seed; median K = 16 ditetapkan untuk partisi akhir. Setelah pilihan itu dibekukan, SCMax diulang dengan seed 0-99 pada data dan embedding yang sama sebagai audit kestabilan pemilihan K. Setiap K pilihan dievaluasi dengan Spectral clustering dan proyeksi citra eksternal yang sama; audit ini tidak mengulang ekstraksi fitur atau bootstrap data.

Spectral clustering membentuk partisi pada graf 15 tetangga terdekat. Nama kelompok dan hubungannya dengan kategori WEEE ditentukan setelah partisi dibekukan melalui pemeriksaan citra. Sebagai analisis hierarki tambahan, centroid dari 16 kelompok akhir digabung secara agglomerative dengan average linkage dan jarak kosinus; prosedur ini tidak mengubah partisi Spectral maupun pemilihan K oleh SCMax. Untuk citra baru, pusat kelompok terdekat memberi penempatan awal. Skor OOD dihitung dari jarak ke tetangga ke-10 pada data utama dan dibandingkan dengan persentil ke-95 skor data utama (Persamaan 5). Ekstraksi fitur dijalankan pada GPU cloud dan tahap clustering pada CPU.

$$s(x) = \|z(x) - z_{(10)}(x)\|_2 \quad (5)$$

2.4 Protokol dan metrik evaluasi

Eksperimen disusun mengikuti empat pertanyaan penelitian. Representasi tunggal dibandingkan untuk mengukur bias sumber; fusi mentah, INLP, LEACE, dan CMRE menguji pengurangan bias; beberapa algoritma clustering membandingkan partisi pada fitur yang sama; Iliev, Shubha, dan Office-Home menguji transfer setelah pipeline dibekukan. K-Means, Ward, GMM, TEMI, TURTLE, dan protokol DECMCV dipakai sebagai pembanding sesuai peran masing-masing. Perbandingan metode pada K tetap memakai reduksi PCA-32 dan K = 16; audit SCMax memakai K pilihan tiap seed. Sapuan parameter r, K, dan jumlah tetangga dilaporkan sebagai sensitivitas; metrik pada data pengembangan tidak dipakai untuk mengklaim validasi independen.

Penilaian dipisahkan menurut pertanyaan penelitian (Tabel 3). Konsistensi lintas sumber, xsrc (Persamaan 6), dihitung dari lima kelas yang sama pada citra produk Kaan dan foto objek Bangladesh. Untuk setiap kelas c, kelompok mayoritas Kaan menjadi acuan; proporsi Bangladesh yang masuk kelompok itu dirata-ratakan antarkelas. Nilai xsrc berada antara 0 dan 1, tetapi nilainya juga dapat tinggi bila kelompok terlalu sedikit. Karena itu, perbandingan metode turut menampilkan Normalized Mutual Information (NMI) objek pada 1.869 citra eksternal berlabel dari Kaan, Bangladesh, dan Karan serta proporsi citra yang diberi kelompok. AMI pada 2.329 citra BDC berlabel dipakai hanya untuk mengaudit partisi final setelah pilihan metode dibekukan. AMI menyesuaikan kesesuaian cluster dan kelas terhadap peluang acak; nilai 1 berarti identik dan nilai sekitar 0 berarti setara acak (Vinh et al., 2010). Kestabilan dibaca dari Jaccard bootstrap per kelompok dan sebaran K antarseed, sedangkan deteksi kategori baru dinilai melalui

AUROC dan alarm palsu pada ambang yang telah ditetapkan. Indeks internal seperti silhouette dipakai sebagai diagnostik, bukan bukti kesamaan objek lintas sumber.

$$\text{xsrc} = \frac{1}{|\mathcal{C}|}\sum_{c\in\mathcal{C}} \frac{1}{|A_c|}\sum_{i\in A_c} \mathbf{1}\,[y_i = m_c] \tag{6}$$

Tabel 3. Metrik inti sesuai pertanyaan penelitian dan batas interpretasinya

Metrik	Pertanyaan dan data	Rentang	Makna dan batas
xsrc makro	Kesamaan kelompok lima kelas pada Kaan dan Bangladesh	0-1; naik	1: semua kelas cocok dengan kelompok acuan; baca bersama NMI dan cakupan.
NMI objek eksternal	Kesesuaian kelompok dengan lima label objek pada 1.869 citra eksternal	0-1; naik	1: partisi identik; belum dikoreksi terhadap kecocokan acak.
AMI objek BDC	Audit partisi akhir pada 2.329 citra berlabel dalam sepuluh kelas	≈0 acak; maks. 1	Nilai negatif mungkin; 1: partisi identik. Tidak dipakai memilih model.
Jaccard bootstrap	Kestabilan anggota tiap kelompok saat data diambil ulang	0-1; naik	1: seluruh anggota pulih; sebaran per kelompok tetap perlu dilaporkan.
AUROC OOD dan alarm palsu	Pemisahan kategori baru dari kategori dikenal pada citra eksternal	0-1	AUROC 0,5 setara acak; alarm palsu lebih kecil lebih baik pada ambang tetap.
Cakupan	Proporsi citra yang memperoleh kelompok	0-1; naik	1: seluruh citra ditetapkan; penting bila suatu metode menolak citra.

3. HASIL DAN PEMBAHASAN

3.1 Bias sumber pada representasi visual

Dalam perbandingan representasi tunggal dengan protokol seragam, SigLIP2 dan CLIP hanya menempatkan sekitar 37% foto objek Bangladesh ke kelompok acuan citra produk Kaan dari kelas yang sama. DINOv3-H+ mencapai 0,86. Pada pasangan model lain yang data pelatihannya sejenis, MetaCLIP berbasis pasangan citra-teks menghasilkan xsrc 0,20, sedangkan Web-DINO tanpa pasangan teks mencapai 0,70 (Xu et al., 2024; Fan et al., 2025). Perbedaan ini konsisten dengan dugaan bahwa supervisi bahasa dapat memperkuat ciri jenis foto. Namun arsitektur dan data pelatihan kedua model tidak sepenuhnya identik, sehingga hasil tersebut belum mengisolasi pengaruh supervisi bahasa.

Kesesuaian terhadap label BDC pada audit awal belum menangkap persoalan ini: NMI objek fusi mentah mencapai 0,948 pada penghitungan awal, tetapi xsrc hanya 0,524.

Nilai NMI tersebut memakai 2.331 entri nama berkas sebelum dua entri upload dipisahkan dari sepuluh kelas objek; karena itu angka tersebut digunakan hanya sebagai diagnostik awal. Perbedaan hasil dalam dan lintas sumber menunjukkan perlunya pengujian transfer, bukan hanya kesesuaian terhadap label BDC.

3.2 Pengaruh CMRE terhadap konsistensi lintas sumber

Pada partisi K = 16, CMRE menaikkan xsrc fusi dari 0,524 menjadi 0,975. NMI objek pada data eksternal naik dari 0,789 menjadi 0,859, dan seluruh citra tetap diberi kelompok (Tabel 4). AMI partisi akhir pada sepuluh label objek BDC mencapai 0,917. Rerata xsrc tidak menutupi variasi kelas: baterai mencapai 0,920, keyboard dan mouse 1,000, ponsel 0,981, serta PCB 0,977. INLP dengan proksi gaya mencapai xsrc yang sama; uji ini belum dapat membedakan kinerja keduanya atau membuktikan kesetaraan. LEACE dengan proksi mencapai 0,792. Pada embedding CMRE yang sama, TURTLE menghasilkan 0,790, TEMI 0,590, dan protokol DECMCV 0,910 dengan cakupan 81% citra; perbedaan cakupan perlu diperhatikan ketika membandingkan skor. Uji bootstrap berpasangan 2.000 kali menunjukkan selisih positif terhadap fusi mentah dan DINOv3 saja pada BDC, Iliev, dan Shubha ($p < 0,001$). Interval selisih terhadap INLP memuat nol. Manfaat praktis CMRE pada pengujian ini ialah tidak perlunya mendefinisikan proksi gaya foto sebelum proyeksi.

Tabel 4. Perbandingan metode pada K = 16 di data pengembangan

Metode	xsrc	NMI objek ekst.	Cakupan
Fusi mentah	0,524	0,789	100%
DINOv3-H+	0,758	0,799	100%
TURTLE†	0,790	n.d.	100%
TEMI†	0,590	n.d.	100%
DECMCV†	0,910	n.d.	81%
LEACE×3	0,792	0,801	100%
INLP×3	0,975	0,853	100%
CMRE cepat	0,951	n.d.	100%
CMRE ringan	0,963	0,852	100%
CMRE usulan	0,975	0,859	100%

xsrc adalah rerata makro lima kelas Kaan-Bangladesh; NMI objek eksternal memakai 1.869 citra dari lima kelas bersama pada Kaan, Bangladesh, dan Karan. Cakupan menunjukkan bagian citra yang tetap diberi kelompok; n.d. berarti NMI belum dihitung dalam arsip pembanding, bukan bernilai nol. Metode bertanda † dijalankan pada

embedding CMRE yang sama dengan K = 16 dan rerata tiga seed. DECMCV membuang citra yang tidak disepakati, sehingga xsrc-nya perlu dibaca bersama cakupan 81%.

Probe linear membantu membaca perubahan pada embedding, tanpa menjadi bukti tunggal mekanismenya. Ketika probe dilatih pada citra produk Kaan dan diuji pada foto objek Bangladesh, akurasi objek naik dari 0,944 menjadi 0,983 setelah CMRE. Arah yang dihapus berkorelasi dengan resolusi ($|\rho|$ hingga 0,68) dan proporsi latar putih (0,39). Namun probe sumber tetap mencapai 0,96-0,99; informasi sumber masih ada, hanya pengaruhnya terhadap kelompok yang berkurang. Acuan berlabel ConvNeXt V2 justru menurunkan xsrc menjadi 0,384. Pada sembilan pasangan model, manfaat CMRE berasosiasi dengan besarnya jejak gaya awal (Spearman 0,78), sedangkan model yang sejak awal tahan bias tidak selalu terbantu.

Pada Iliev, yang pemetaan kelas dan metriknya dikunci sebelum data diunduh, xsrc eksternal mencapai 0,885 dengan interval kepercayaan 95% sebesar 0,864-0,908; fusi mentah mencapai 0,803 dan DINOv3 saja 0,755. Purity pada set ini 0,939. Iliev kemudian dipakai memilih skor OOD, sehingga statusnya sebagai set terkunci berlaku untuk evaluasi clustering, bukan untuk OOD. Pada Shubha, set konfirmasi awal berisi 300 crop, xsrc naik dari 0,356 pada fusi mentah menjadi 0,956 (interval 0,924-0,983) setelah CMRE. Office-Home memberi kondisi pembanding: fusi mentah sudah memiliki xsrc 0,865 dan CMRE menghasilkan 0,864, sementara silhouette naik dari 0,39 menjadi 0,48. Dengan demikian, peningkatan terbesar muncul ketika bias sumber awal memang kuat; hasil Office-Home tidak mendukung klaim bahwa CMRE selalu memperbaiki transfer. Audit tambahan setelah partisi v4 dibekukan menguji AIMv2-L, encoder yang dilatih dengan prediksi autoregresif citra dan teks (Fini et al., 2025). AIMv2 sendiri mencapai xsrc 0,842 pada protokol Spectral K = 16. Penambahan AIMv2 pada fusi CMRE(SigLIP2), CMRE(PE), dan DINOv3 menaikkan xsrc BDC dari 0,970 menjadi 0,987 ketika kedua representasi dihitung ulang dengan protokol yang sama. Namun pada Iliev selisihnya hanya 0,002 (IK95% bootstrap berpasangan -0,012 hingga 0,015), dan pada Shubha 0,011 (0,000 hingga 0,028). Karena interval tersebut memuat atau menyentuh nol, fusi empat model belum menggantikan pipeline v4. Rincian varian dan protokol tercantum pada lampiran.

3.3 Pemilihan jumlah kelompok dan sensitivitas parameter

Audit 100 seed SCMax menghasilkan median K = 16 dan modus 17. Frekuensinya: K = 13 (2 seed), 14 (10), 15 (20), 16 (20), 17 (21), 18 (14), 19 (10), 20 (2), dan 21 (1). Partisi final tetap memakai K = 16 yang telah dipilih dari sembilan seed awal; audit tambahan ini tidak dipakai memilih ulang K. Ketika Spectral mengikuti K pilihan masing-masing seed, xsrc mencapai 0,923 ± 0,098 (rerata ± simpangan baku; rentang 0,596-0,988), sedangkan NMI objek eksternal 0,854 ± 0,022. ARI antarpasangan 100 partisi rerata 0,861 ± 0,110. Pada 27 seed yang memilih K sedikitnya 18, xsrc hanya 0,596-0,794; pada K = 13-17 nilainya 0,972-0,988. Sebaran antar-seed ini menunjukkan ketidakpastian algoritmik, bukan interval kepercayaan generalisasi. Partisi Spectral pada K yang berbeda dijalankan secara terpisah, sehingga kemiripan K = 13 dan K = 16 tidak boleh disebut hierarki bersarang. Hierarki tambahan dibangun sesudah partisi K = 16 melalui penggabungan centroid. Empat penggabungan awal ialah dua jenis mesin cuci, dua baterai perangkat, dua pemutar audio, lalu dua televisi. Keempat cabang pulih pada 200 dari 200 bootstrap yang mempertahankan anggota tiap cluster; uji ini belum menilai kestabilan jika SCMax dan Spectral dijalankan ulang.

Uji sensitivitas menunjukkan xsrc 0,97-0,99 untuk r = 16-64, tetapi 0,449 pada r = 4 dan 0,821 pada r = 128. Nilai α dari 0,01 sampai 1 memberi xsrc 0,975-0,983, lalu menurun pada α yang lebih besar. Pada K = 16, Spectral menghasilkan xsrc 0,975, dibanding K-Means 0,949, GMM 0,926, dan Ward 0,836. K-Means justru memiliki silhouette sedikit lebih tinggi (0,398 dibanding 0,364), kembali menunjukkan keterbatasan indeks internal untuk bias sumber. Pada graf Spectral dengan 15-30 tetangga, xsrc berada pada 0,975-0,988; pemakaian 5-10 tetangga menurunkannya ke sekitar 0,91. Dengan K dibekukan pada 16, empat seed tambahan Spectral menghasilkan ARI 1,00 terhadap partisi final; angka itu tidak mencakup variasi K dari SCMax. Sebelas dari 16 kelompok mencapai Jaccard bootstrap sedikitnya 0,85.

3.4 Penafsiran kelompok dan batas taksonomi

Tabel 5 memuat isi dominan, jumlah citra, kestabilan, dan penafsiran penanganan untuk keenam belas kelompok. Nama kelompok berasal dari pemeriksaan citra setelah partisi selesai; nama tersebut tidak menjadi target model. Pemetaan WEEE dan B3 digunakan untuk membaca kegunaan kelompok, bukan sebagai label pelatihan.

Tabel 5. Interpretasi kelompok dan implikasi penanganannya

C	Isi kelompok	n	Kategori WEEE / B3	Jaccard	Implikasi penanganan
0	Aki timbal-asam	115	baterai (B3)	0,71	timbal dan asam sulfat; daur ulang aki khusus
1	Baterai pack laptop	70	baterai Li-ion	0,94	risiko kebakaran; lepas sebelum pencacahan
2	Turntable	111	5 (Small equipment)	0,96	pembongkaran umum
3	TV/monitor CRT	174	2 (Screens & monitors)	0,79	kaca bertimbal; perlakuan selektif
4	Baterai ponsel/kamera	136	baterai Li-ion kecil	0,82	titik kumpul baterai
5	Pemutar CD/radio	153	5 (Small equipment)	0,97	pembongkaran umum
6	Mesin cuci bukaan atas	115	4 (Large equipment)	0,98	logam dan motor
7	TV/monitor layar datar	263	2 (Screens & monitors)	0,85	lampu latar lama dapat mengandung merkuri
8	Mesin cuci front-load	192	4 (Large equipment)	0,99	logam dan motor
9	Laptop	277	2 (Screens & monitors)	0,98	baterai, layar, dan PCB bernilai
10	Keyboard	320	6 (Small IT & Telecom)	0,90	plastik dominan
11	Microwave	275	5 (Small equipment)	1,00	kapasitor tegangan tinggi
12	Printer	294	6 (Small IT & Telecom)	1,00	kartrid toner
13	Mouse	291	6 (Small IT & Telecom)	1,00	plastik dominan
14	Ponsel	366	6 (Small IT & Telecom)	0,94	baterai dan PCB bernilai
15	PCB dan tumpukan campuran	640	komponen	0,85	logam mulia; perlu pra-pemilahan

Empat pasangan pertama pada hierarki centroid mempunyai hubungan visual yang mudah dibaca: mesin cuci bukaan atas dan depan, baterai laptop dan baterai kecil, dua jenis pemutar audio, serta TV CRT dan layar datar. Pada potongan 12 kelompok, penggabungan pasangan tersebut mempertahankan purity BDC 0,993 pada 2.329 citra berlabel dan xsrc 0,975. Pada potongan delapan kelompok, purity turun menjadi 0,796 karena kategori berbeda mulai bergabung. Ini mendukung penggunaan hierarki dangkal sebagai ringkasan, bukan klaim bahwa seluruh pohon mencerminkan taksonomi penanganan. Kelompok C9 didominasi laptop meskipun nama berkas BDC mengaitkannya dengan keyboard; 96,7% foto laptop Iliev masuk ke kelompok itu. Pada citra Iliev yang dikenali, kesesuaian kelompok dengan kategori EU-6 mencapai 79%, dibanding 19% pada 100.000 penggabungan acak dengan ukuran grup sama ($p < 0,001$). Namun jarak antarpusat kelompok dalam satu kategori WEEE tidak lebih kecil dari acak ($p = 0,46$). Kategori WEEE karena itu lebih tepat diperlakukan sebagai lapisan interpretasi setelah clustering.

Kesalahan lintas sumber tetap ada. Dari 449 foto objek Bangladesh pada lima kelas bersama, 12 tidak masuk kelompok mayoritas citra produk Kaan: tujuh baterai masuk

kelompok aki, tiga PCB masuk baterai ponsel, dan dua ponsel masuk baterai. Beberapa stop kontak juga masuk C0, kemungkinan karena bentuk kotak dan terminal logamnya. Foto tumpukan campuran banyak terkumpul pada C15 bersama papan sirkuit. Kelompok aki, CRT, dan baterai kecil memiliki Jaccard bootstrap 0,71-0,82, lebih rendah daripada kelompok lain. Dengan demikian, kemurnian agregat yang tinggi tidak menghapus kebutuhan meninjau kelompok yang kecil dan bentuk objek yang saling menyerupai.

3.5 Deteksi perangkat di luar kategori

Jarak ke tetangga terdekat menghasilkan AUROC OOD 0,937 pada Iliev, dibanding 0,868 untuk jarak ke pusat kelompok. Iliev dipakai memilih skor ini, sehingga angka tersebut merupakan hasil pengembangan OOD. Pada Shubha, AUROC mencapai 0,994 dengan interval kepercayaan 95% sebesar 0,984-0,999, tetapi hanya dua kelas di luar kategori yang tersedia. Ambang persentil ke-95 menandai 94% foto lampu Bangladesh yang tidak terwakili pada BDC, sekaligus keliru menandai 13% foto objek Bangladesh dari kelas dikenal. Di Iliev, AC ditandai pada 97% foto, kulkas 83%, serta setrika, kipas angin, lampu LED, dan dispenser air masing-masing 100%; pemutar MP3 portabel juga sering ditandai karena kelas pemutar BDC didominasi perangkat yang lebih besar.

Sebanyak 44,5% foto lapangan GIZ melewati ambang OOD. Di antara foto yang ditandai, banyak terdapat AC, kulkas, dan kompresor, jenis perangkat yang tidak terdapat dalam kelompok utama BDC. Temuan ini menunjukkan fungsi praktis alarm kategori baru, tetapi proporsi yang ditandai sendiri bukan ukuran akurasi karena tidak semua foto GIZ memiliki padanan label yang lengkap. Foto yang ditandai perlu diperiksa petugas sebelum diberi arahan penanganan.

3.6 Hubungan dengan studi terdahulu dan penggunaan di Indonesia

DECMCV telah melaporkan bahwa perbedaan gaya foto mengganggu pengelompokan sampah (Huang et al., 2025). Penelitian ini menambahkan ukuran konsistensi lintas sumber dan menguji proyeksi residu sebagai cara mengurangi gangguan tersebut tanpa membuang citra. Dibanding studi klasifikasi terawasi seperti Islam et al. (2023), persoalan yang ditangani berbeda: kategori belum ditetapkan saat pembentukan kelompok. Karena itu, akurasi klasifikasi pada satu dataset tidak dapat dibandingkan langsung dengan xsrc penelitian ini. Pemisahan subtipe perangkat konsisten dengan pengamatan Zhou et al. (2025) tentang kegunaan tipe produk dalam pembongkaran, tetapi

relevansi operasional tiap kelompok masih memerlukan penilaian ahli pengelolaan e-waste.

Dalam konteks Indonesia, hasil ini dapat menjadi bahan awal bagi alat bantu triase foto di bank sampah atau tempat pengumpulan. Sistem semacam itu perlu menampilkan kelompok yang diperkirakan, skor ketidakpastian, serta pilihan pemeriksaan manual untuk foto yang ditandai OOD. Versi cepat dengan SigLIP2 dan DINOv3 memproses sekitar 20 citra per detik pada GPU L4, dibanding 3,4 citra per detik untuk pipeline penuh; xsrc-nya 0,951 pada BDC, 0,860 pada Iliev, dan 0,922 pada Shubha. Angka ini menunjukkan pilihan biaya komputasi dan kinerja, bukan pengukuran pada ponsel. Uji pada foto rumah tangga Indonesia dan pemeriksaan jalur penanganan oleh petugas tetap diperlukan sebelum penerapan.

3.7 Keterbatasan

Batas utama penelitian terletak pada protokol data. BDC digunakan berulang kali untuk memilih varian, sehingga xsrc 0,975 bersifat optimistis. Iliev memberi uji clustering terkunci, sedangkan Shubha baru mencakup 300 crop. Belum ada foto yang diambil langsung dari rumah tangga atau bank sampah di Indonesia. Dari sisi metode, selisih CMRE terhadap INLP belum signifikan pada metrik utama, dan manfaat CMRE bergantung pada kekuatan model SSL acuan; dengan DINOv3-B, xsrc hanya 0,593. Informasi sumber masih terbaca oleh probe. Pada audit 100 seed, SCMax memilih K antara 13 dan 21; 27 seed dengan K sedikitnya 18 menghasilkan xsrc paling tinggi 0,794. Bootstrap hierarki belum mencakup pelatihan ulang pipeline. Deteksi OOD memakai satu ambang global yang menandai 13% foto objek Bangladesh dari kelas dikenal. Hasil eksternal juga dipengaruhi kesesuaian definisi kelas: pemutar MP3 dan TV Iliev tidak selalu sepadan dengan kelompok BDC.

4. PENUTUP

Representasi visual pada data ini memang peka terhadap sumber foto: SigLIP2 dan CLIP memberi xsrc sekitar 0,37, sedangkan DINOv3-H+ mencapai 0,86 pada audit awal. CMRE menaikkan xsrc fusi dari 0,524 menjadi 0,975; AMI partisi akhir pada sepuluh kelas BDC adalah 0,917. Perbaikan xsrc juga tampak pada Iliev (0,803 menjadi 0,885) dan Shubha (0,356 menjadi 0,956), sementara Office-Home menunjukkan kondisi tanpa perbaikan. Median sembilan seed awal SCMax memilih K = 16. Audit 100 seed memberi

median yang sama, tetapi partisi antar-seed hanya mencapai rerata ARI 0,861; kestabilan jumlah kelompok masih menjadi batas metode. Kelompok akhir memisahkan beberapa subtipe perangkat; hierarki centroid pascacluster berguna sampai penggabungan awal, sedangkan cabang atas tidak selalu sejalan dengan kategori penanganan. Deteksi OOD kNN mencapai AUROC 0,994 pada Shubha dengan dua kelas baru dan tetap menghasilkan alarm palsu pada 13% foto Bangladesh dari kelas dikenal. Dengan bukti saat ini, pipeline merupakan dasar eksplorasi kategori dan triase foto, belum pengganti penilaian petugas pada konteks Indonesia.

Pengujian berikutnya perlu mengumpulkan foto langsung dari rumah tangga dan bank sampah Indonesia, terutama perangkat penukar suhu dan foto tumpukan yang kurang terwakili. Pemetaan kategori harus dikunci sebelum data tersebut dinilai agar estimasi transfer tidak kembali menjadi hasil pengembangan. Ablasi yang memisahkan efek regresi, proyeksi residu, dan model acuan diperlukan untuk menjelaskan kontribusi CMRE. Variasi K dapat diuji dengan mengulangi seluruh pipeline pada sampel baru, bukan hanya bootstrap centroid; ambang OOD per kelompok juga perlu dikalibrasi pada set pengembangan terpisah. Untuk pemakaian pada perangkat terbatas, versi cepat SigLIP2 dan DINOv3 dapat menjadi titik awal distilasi serta pengukuran latensi yang sesungguhnya.

REFERENSI

Adaloglou, N., Michels, F., Kalisch, H., & Kollmann, M. (2023). Exploring the limits of deep image clustering using pretrained models. *Proceedings of the British Machine Vision Conference (BMVC)*.

Baldé, C. P., Kuehr, R., Yamamoto, T., et al. (2024). *The global e-waste monitor 2024*. International Telecommunication Union & United Nations Institute for Training and Research. https://ewastemonitor.info

Belrose, N., Schneider-Joseph, D., Ravfogel, S., Cotterell, R., Raff, E., & Biderman, S. (2023). LEACE: Perfect linear concept erasure in closed form. *Advances in Neural Information Processing Systems, 36*.

Bolya, D., et al. (2025). Perception Encoder: The best visual embeddings are not at the output of the network. *arXiv:2504.13181*.

Defitri, M. (2022, 12 Oktober). *Pengelolaan sampah elektronik dan peraturannya di Indonesia*. Waste4Change. https://waste4change.com/blog/pengelolaan-sampah-elektronik-dan-peraturannya-di-indonesia/

European Parliament and Council. (2012). Directive 2012/19/EU on waste electrical and electronic equipment (WEEE). *Official Journal of the European Union, L 197*.

Fan, D., et al. (2025). Scaling language-free visual representation learning. *arXiv:2504.01017*.

Fini, E., et al. (2025). Multimodal autoregressive pre-training of large vision encoders. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). https://openaccess.thecvf.com/content/CVPR2025/html/Fini_Multimodal_Autoregressive_Pre-training_of_Large_Vision_Encoders_CVPR_2025_paper.html

Gadetsky, A., Jiang, Y., & Brbić, M. (2024). Let go of your labels with unsupervised transfer. *Proceedings of the 41st International Conference on Machine Learning (ICML)*.

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence, 2*(11), 665-673.

Gundupalli, S. P., Hait, S., & Thakur, A. (2018). Classification of metallic and non-metallic fractions of e-waste using thermal imaging-based technique. *Process Safety and Environmental Protection*. https://www.sciencedirect.com/science/article/abs/pii/S0957582018303434

Hennig, C. (2007). Cluster-wise assessment of cluster stability. *Computational Statistics & Data Analysis, 52*(1), 258-271.

Huang, K., Song, M., Ba, S., An, L., Liang, H., Deng, H., Liu, Y., Zhang, Z., & Zhou, C. (2025). Unsupervised waste classification by dual-encoder contrastive learning and multi-clustering voting (DECMCV). *arXiv:2503.02241*.

Islam, N., Jony, M. M. H., Hasan, E., Sutradhar, S., Rahman, A., & Islam, M. M. (2023). EWasteNet: A two-stream data efficient image transformer approach for e-waste classification. *arXiv:2311.12823*.

Jano, T., et al. (2026). Closing the loop: A systematic review of artificial intelligence in circular e-waste management. *Waste Management, 214*, 115392.

Liang, J., Hou, R., Hu, M., Chang, H., Shan, S., & Chen, X. (2024). UMFC: Unsupervised multi-domain feature calibration for vision-language models. *Advances in Neural Information Processing Systems, 37*. https://doi.org/10.52202/079017-3623

Ng, A. Y., Jordan, M. I., & Weiss, Y. (2002). On spectral clustering: Analysis and an algorithm. *Advances in Neural Information Processing Systems, 14*.

Pemerintah Republik Indonesia. (2020). *Peraturan Pemerintah Nomor 27 Tahun 2020 tentang Pengelolaan Sampah Spesifik*.

Rajeev, P. A., Dharewa, V., Lakshmi, D., et al. (2025). Advancing e-waste classification with customizable YOLO based deep learning models. *Scientific Reports, 15*, 18151. https://doi.org/10.1038/s41598-025-94772-x

Ravfogel, S., Elazar, Y., Gonen, H., Twiton, M., & Goldberg, Y. (2020). Null it out: Guarding protected attributes by iterative nullspace projection. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7237-7256.

Siméoni, O., et al. (2025). DINOv3. *arXiv:2508.10104*.

Sun, Y., Ming, Y., Zhu, X., & Li, Y. (2022). Out-of-distribution detection with deep nearest neighbors. *Proceedings of the 39th International Conference on Machine Learning (ICML)*, 20827-20840.

Tschannen, M., et al. (2025). SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. *arXiv:2502.14786*.

Venkateswara, H., Eusebio, J., Chakraborty, S., & Panchanathan, S. (2017). Deep hashing network for unsupervised domain adaptation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 5018-5027.

Vinh, N. X., Epps, J., & Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. Journal of Machine Learning Research, 11, 2837-2854. https://jmlr.org/papers/v11/vinh10a.html

Wang, H., He, Z., Lipton, Z. C., & Xing, E. P. (2019). Learning robust representations by projecting superficial statistics out. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/1903.06256

Xu, H., et al. (2024). Demystifying CLIP data. *Proceedings of the International Conference on Learning Representations (ICLR)*.

Yalavarthi, B. C., Ratha, N., & Govindaraju, V. (2026). Label-free mitigation of spurious correlations in VLMs using sparse autoencoders. *International Conference on Learning Representations (ICLR)*.

Zhang, L., Liu, S., Wang, S., Yu, S., Zhu, X., Li, M., & Liu, X. (2026). Parameter-free clustering via self-supervised consensus maximization. *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI-26)*.

Zhou, C., Sterkens, W., Díaz-Romero, D. J., Zaplana, I., & Peeters, J. (2023). You only demanufacture once (YODO): WEEE retrieval using unsupervised learning. *Resources, Conservation & Recycling, 190*, 106826.

Zhou, C., Wu, Y., Sterkens, W., Vandewalle, P., Zhang, J., & Peeters, J. R. (2025). Multi-view graph transformer for WEEE classification and retrieval. *Resources, Conservation & Recycling, 215*, 108112.

Sumber data tambahan: Kaan Erkez, Waste Classification Dataset (https://www.kaggle.com/datasets/kaanerkez/waste-classfication-dataset); Custom Bangladeshi E-Waste (https://data.mendeley.com/datasets/77383kmdnw/1); Karan Solanki, Garbage Classification (https://www.kaggle.com/datasets/karansolanki01/garbage-classification); GIZ, E-Waste Database (https://huggingface.co/datasets/GIZ/E-Waste-Database); Electronic Waste Detection (Iliev), E-Waste Dataset

(https://universe.roboflow.com/electronic-waste-detection/e-waste-dataset-r0ojc); Shubha, E-waste Dataset (https://universe.roboflow.com/shubha-to6ii/e-waste-1sn3k); Office-Home (https://huggingface.co/datasets/flwrlabs/office-home).

LAMPIRAN

Kode reproduksi untuk ekstraksi fitur, clustering, dan evaluasi tersedia di https://github.com/elzaff/cross-model-residual-erasure-clustering-bdc-ewaste. Cuplikan berikut memperlihatkan operasi inti.

```
import numpy as np
from sklearn.cluster import SpectralClustering
from sklearn.decomposition import PCA
from sklearn.linear_model import Ridge
from sklearn.neighbors import NearestNeighbors
def l2(x):
    return x / (np.linalg.norm(x, axis=1, keepdims=True) + 1e-8)
def cmre(v, ref, r=64, alpha=1.0):
    """Cross-Model Residual Erasure: remove from the VLM embeddings v the top-r principal
directions of the part
    that the self-supervised reference cannot predict. Returns the cleaned embeddings and the
projector P,
    which is applied unchanged to new images (v_new @ P)."""
    residual = v - Ridge(alpha=alpha).fit(ref, v).predict(ref)          # Eq. 1-2
    U = PCA(r, random_state=0).fit(residual).components_                 # top-r residual
directions
    P = np.eye(v.shape[1], dtype=v.dtype) - U.T @ U
    return l2(v @ P), P                                                  # Eq. 3
def fuse(parts, dim=32):
    """Concatenate the cleaned embeddings, reduce with PCA and re-normalise (Eq. 4)."""
    x = l2(np.hstack(parts))
    pca = PCA(dim, random_state=0).fit(x)
    return l2(pca.transform(x)), pca
def cluster(z, k=16, n_neighbors=15, seed=0):
    """Spectral clustering on a k-nearest-neighbour graph; k = median SCMax choice over 9
seeds."""
    return SpectralClustering(k, affinity="nearest_neighbors", n_neighbors=n_neighbors,
                              random_state=seed, assign_labels="cluster_qr").fit_predict(z)
class KnnOOD:
    """kNN out-of-distribution detector (Sun et al., 2022): distance to the k-th nearest D_main
image (Eq. 5);
    an image is 'unknown' above the q-th percentile of the D_main scores (leave-one-out)."""
    def __init__(self, z_main, k=10, q=95):
        self.k = k
        self.nn = NearestNeighbors(n_neighbors=k + 1).fit(z_main)
        self.threshold = np.percentile(self.nn.kneighbors(z_main)[0][:, k], q)
    def score(self, z):
        return self.nn.kneighbors(z, self.k)[0][:, -1]
    def is_unknown(self, z):
        return self.score(z) > self.threshold
def run(sig, pe, dino, k=16):
    """Full pipeline on D_main: returns the fused features, cluster labels and the OOD
detector."""
    sig_clean, _ = cmre(sig, dino)
    pe_clean, _ = cmre(pe, dino)
    z, _ = fuse([sig_clean, pe_clean, dino])
    return z, cluster(z, k), KnnOOD(z)
```

Tabel 6. CMRE dengan model acuan berbeda (BDC, K = 16), diurutkan menurut R^2 ridge tanpa label

Model acuan	Jenis	R^2 ridge	xsrc mentah	xsrc CMRE
DINOv3-7B	SSL	0,434	0,568	0,983
DINOv3-H+ (usulan)	SSL	0,403	0,524	**0,975**
ConvNeXt V2-H	berlabel	0,392	0,480	0,384
DINOv3-L	SSL	0,390	0,550	0,596
Web-DINO-1B	SSL	0,382	0,550	0,917
Web-DINO-300M	SSL	0,358	0,591	0,930
DINOv2-L	SSL	0,351	0,516	0,777
DINOv3-B	SSL	0,347	0,481	0,593
DINOv3-ConvNeXt-L	SSL	0,345	0,593	0,726

R^2 ridge: kemampuan acuan memprediksi embedding VLM (validasi silang 5 lipatan, tanpa label). Korelasi peringkat R^2 dengan xsrc pada delapan acuan SSL = 0,69; acuan berlabel dikecualikan secara prinsip.

Tabel 7. Uji bootstrap berpasangan: selisih xsrc usulan dikurangi pembanding [IK95%], 2.000 ulangan

Pembanding	BDC	Iliev	Shubha
Fusi mentah	+0,451 [0,429; 0,476]	+0,082 [0,057; 0,106]	+0,600 [0,559; 0,637]
DINOv3-H+ saja	+0,217 [0,188; 0,244]	+0,130 [0,113; 0,149]	+0,067 [0,034; 0,105]
INLP ×3 (butuh proksi)	−0,008 [−0,021; 0,005]	+0,003 [−0,017; 0,023]	−0,017 [−0,037; 0,000]
Versi ringan PE + DINOv3	+0,006 [−0,010; 0,021]	+0,003 [−0,008; 0,017]	+0,011 [0,000; 0,029]
Versi cepat SigLIP2 + DINOv3	+0,024 [0,005; 0,047]	+0,025 [0,009; 0,043]	+0,033 [0,011; 0,061]

Nilai positif berarti usulan lebih tinggi. Selisih terhadap INLP dan versi ringan tidak signifikan (interval memuat nol).

Lampiran A. Audit fusi AIMv2

Fusi berikut memakai PCA 32 dimensi dan Spectral K = 16 dengan 15 tetangga pada 3.792 citra utama BDC, rerata tiga seed. Seluruh bagian dinormalisasi L2 sebelum dikonkatenasi. Nilai v4 pada tabel dihitung ulang secara lokal untuk perbandingan setara; artefak final tersimpan mencatat xsrc 0,975. Penyebab selisih kecil dengan hitung ulang (0,970) belum diisolasi.

Representasi	xsrc BDC	NMI ekst.	Purity BDC
AIMv2-L	0,842	0,801	0,974
CMRE(Sig) + CMRE(PE) + DINO (v4 hitung ulang)	0,970	0,854	0,992
AIM + Sig mentah + DINO	0,564	0,790	0,989
AIM + PE mentah + DINO	0,601	0,797	0,992
AIM + Sig mentah + PE mentah + DINO	0,539	0,793	0,994
AIM + CMRE(Sig) + DINO	0,940	0,823	0,990
AIM + CMRE(PE) + DINO	0,965	0,856	0,992
AIM + CMRE(Sig) + CMRE(PE) + DINO	0,987	0,865	0,994

Kandidat empat model dipilih pada BDC sebelum dievaluasi di luar data tersebut. Pada Iliev, xsrc v4 0,885 dan kandidat 0,887 (selisih +0,002; IK95% [-0,012; 0,015]); pada Shubha, 0,956 dan 0,967 (+0,011; [0,000; 0,028]). Interval berasal dari 2.000 bootstrap berpasangan dalam tiap kelas. Purity tidak berubah: 0,939 di Iliev dan 1,000 di Shubha. Pemilihan K dengan SCMax serta audit 100 seed belum diulang untuk kandidat.