PENGELOMPOKAN SAMPAH ELEKTRONIK TANPA LABEL DARI CITRA MULTISUMBER DENGAN *CROSS-MODEL RESIDUAL ERASURE* DAN *SPECTRAL CLUSTERING*

**Studi Kasus Pemilahan Sampah Spesifik di Indonesia**

PENGELOMPOKAN SAMPAH ELEKTRONIK TANPA LABEL DARI CITRA MULTISUMBER DENGAN *CROSS-MODEL RESIDUAL ERASURE* DAN *SPECTRAL CLUSTERING*

Studi Kasus Pemilahan Sampah Spesifik di Indonesia

**Abstrak**

Latar dan resolusi foto dapat membuat sampah elektronik sejenis terpisah saat dikelompokkan tanpa label. Kami menguji 3.792 citra BDC dengan *embedding* SigLIP2, *Perception Encoder*, dan DINOv3. *Cross-Model Residual Erasure* (CMRE) memproyeksikan keluar arah dominan dari bagian *embedding* visi-bahasa yang tidak dapat diprediksi DINOv3. Langkah ini tidak memerlukan label objek atau proksi gaya. SCMax memilih jumlah kelompok, *Spectral clustering* membentuk partisi, dan jarak tetangga terdekat menandai citra di luar cakupan kelompok. Pada data pengembangan, **CMRE menaikkan konsistensi lintas sumber dari 0,524 menjadi 0,975**. ***Adjusted Mutual Information* (AMI) pada 2.329 citra BDC berlabel mencapai 0,917**. CMRE tidak berbeda signifikan dari INLP yang memakai proksi gaya. Audit 100 *seed* SCMax memberi median K = 16, tetapi **hanya 20 *seed* memilih angka itu**. Pada Iliev, konsistensi naik dari 0,803 menjadi 0,885 dan pada Shubha dari 0,356 menjadi 0,956. Enam belas kelompok akhir memisahkan subtipe baterai, perangkat berlayar, dan mesin cuci. Deteksi kategori baru mencapai AUROC 0,994 pada Shubha yang hanya menyediakan dua kelas baru. Hasil ini berlaku untuk sumber foto yang diuji. Foto rumah tangga Indonesia masih memerlukan pengujian tersendiri.

Kata kunci: sampah elektronik, pengelompokan tanpa label, bias sumber foto, representasi visual, deteksi kategori baru

## 1. PENDAHULUAN

Dunia menghasilkan 62 juta ton sampah elektronik pada 2022. Dari jumlah itu, 22,3% tercatat dikumpulkan dan didaur ulang secara layak (Baldé et al., 2024). Di Indonesia, perkiraan timbulan 2021 mencapai 2 juta ton dan 17,4% di antaranya dikelola dengan baik (Defitri, 2022). Pemilahan awal menentukan jalur pengolahan, padahal perangkat yang tampak serupa dapat mengandung bahan berbahaya yang berbeda.

Aki dan kaca tabung CRT mengandung timbal. Baterai litium dapat terbakar ketika rusak. Beberapa lampu serta layar lama mengandung merkuri. Peraturan Pemerintah Nomor 27 Tahun 2020 mengatur sampah yang mengandung bahan berbahaya dan beracun sebagai sampah spesifik (Pemerintah Republik Indonesia, 2020). Karena itu, salah mengenali perangkat pada tahap pemilahan dapat berdampak pada keselamatan pembongkaran dan pilihan jalur pengolahan.

Petugas dapat memakai foto untuk mengenali perangkat sebelum memilahnya. Citra produk berlatar putih, foto objek dengan latar beragam, dan foto lapangan memberi model ciri akuisisi yang berbeda. Jika model mengikuti ciri itu, perangkat sejenis dapat terpisah ke kelompok berbeda. Pelabelan manual ribuan foto memerlukan tenaga, sementara daftar kategori awal dapat melewatkan subtipe perangkat. Penelitian ini menguji pengelompokan tanpa label pada foto dari beberapa sumber.

Gundupalli et al. (2018) memilah fraksi material dari citra termal yang memerlukan kamera khusus (Tabel 1). Islam et al. (2023) dan Rajeev et al. (2025) meneliti klasifikasi serta deteksi pada kelas yang telah ditetapkan dan memakai label saat pelatihan. YODO menelusuri laptop di lini pembongkaran tanpa label (Zhou et al., 2023). DECMCV mengelompokkan sampah umum tanpa label, tetapi membuang citra ketika metode-metodenya tidak sepakat. Penulisnya juga melaporkan gangguan akibat gaya foto (Huang et al., 2025). Studi tersebut belum mengukur apakah foto perangkat sejenis dari sumber berbeda tetap berada dalam kelompok yang sama.

Tabel 1. Ringkasan penelitian terdahulu

| Studi | Data dan metode | Hasil (metrik) | Kelebihan | Keterbatasan |
|---|---|---|---|---|
| Gundupalli et al. (2018) | Citra termal LWIR, fitur intensitas, 4 fraksi material | Akurasi 84-96% | Memilah material langsung di lini daur ulang | Butuh kamera termal, bukan foto biasa |
| Islam et al. (2023), EWasteNet | 8 jenis perangkat, *transformer* DeiT dua aliran (terawasi) | Akurasi 96% | Akurasi tinggi pada 8 jenis perangkat | Butuh label, kategori tetap, satu sumber data |
| Rajeev et al. (2025) | 700 citra, 7 jenis komponen, YOLOv5/v7/v8 | YOLOv8: presisi 0,832, mAP50 0,821 | Melokalisasi komponen, bukan hanya mengklasifikasi | Terawasi, skala komponen, data kecil |
| Zhou et al. (2023), YODO | Penelusuran WEEE tanpa label di lini pembongkaran | Retrieval laptop tanpa label | Tanpa label, terhubung ke proses pembongkaran | Satu jenis produk, lingkungan terkendali |
| Huang et al. (2025), DECMCV | Sampah umum, ConvNeXt + ViT kontrastif, voting multi-*clustering* | Akurasi 93,78% (TrashNet) | Tanpa label, menyadari masalah gaya foto | Membuang data yang tidak disepakati, bias gaya belum diukur |

### 1.1 Rumusan masalah

Masalah penelitian dirumuskan dalam empat pertanyaan. Pertama, apakah representasi visual lebih dipengaruhi sumber foto daripada jenis perangkat? Kedua, dapatkah pengaruh tersebut dikurangi tanpa label atau proksi gaya? Ketiga, apakah kelompok yang terbentuk cukup stabil dan dapat ditafsirkan setelah jumlah kelompok dipilih tanpa label? Keempat, apakah foto dari sumber lain dan perangkat di luar kategori dapat ditangani tanpa membentuk ulang kelompok?

### 1.2 Tujuan dan batasan penelitian

Kami membentuk kelompok pada citra utama BDC, lalu menilai citra eksternal dengan representasi dan partisi yang sudah tetap. Label dari nama berkas dan kategori WEEE baru dipakai untuk menafsirkan kelompok setelah partisi selesai. CMRE memprediksi *embedding* visi-bahasa dari DINOv3 dan membuang arah dominan pada residunya. SCMax memilih K, *Spectral clustering* membentuk kelompok, dan jarak tetangga menandai citra di luar cakupan. Rancangan ini memungkinkan pengujian bias sumber tanpa proksi gaya, *transfer* antar sumber foto, dan deteksi kategori baru. Pemakaian untuk pemilahan nyata masih memerlukan pengujian pada foto dari Indonesia.

## 2. METODOLOGI

### 2.1 Data dan pemisahan peran *dataset*

Dari 3.961 citra e-waste BDC, deduplikasi *perceptual hash* pada jarak Hamming 6 menyisakan 3.604 citra latih unik. Data utama juga mencakup 188 citra uji penyisihan yang dipilih berdasarkan prediksi pengklasifikasi SigLIP2 dari babak sebelumnya. Label panitia tidak tersedia pada tahap ini. Jumlah akhirnya 3.792 citra. Ketika seluruh *pipeline* diulang pada 3.604 citra latih saja, xsrc tetap 0,975 dan ARI terhadap partisi utama pada citra latih mencapai 0,93. Nama berkas memberi label objek valid untuk 2.329 citra dalam sepuluh kelas. Dua entri bernama upload dikeluarkan dari evaluasi kelas dan 1.461 citra tidak memiliki label nama berkas. Ekstraksi fitur, pemilihan K, dan pembentukan *cluster* tidak memakai label tersebut.

Tujuh set data publik melengkapi evaluasi dengan peran yang berbeda (Tabel 2). Citra eksternal mendapat kelompok berdasarkan partisi BDC yang tetap, tanpa pelatihan ulang. Audit *perceptual hash* menemukan bahwa 55% citra Kaan beririsan dengan BDC.

Duplikat itu dibuang sebelum evaluasi untuk mencegah kebocoran. Protokol dan pemetaan kelas Iliev serta Shubha ditetapkan sebelum data diunduh. Sebaliknya, lebih dari 40 varian metode dibandingkan memakai xsrc BDC, sehingga nilainya merupakan hasil pengembangan. Office-Home hanya dipakai untuk pengujian sesuai lisensi riset nonkomersial.

Tabel 2. Sumber data yang digunakan

| Sumber | Jumlah | Jenis foto | Peran | Lisensi |
|---|---|---|---|---|
| BDC (latih + uji penyisihan) | 3.792 | citra campuran | data utama (*clustering*) | panitia |
| Kaan, Waste Classification (Kaggle) | 1.794 | citra produk | evaluasi objek | CDLA-Permissive-1.0 |
| Custom Bangladeshi E-Waste (Mendeley) | 480 | foto objek | evaluasi lintas sumber | CC BY 4.0 |
| Garbage Classification, baterai (Kaggle) | 499 | web | evaluasi objek | Apache 2.0 |
| GIZ E-Waste Database (Hugging Face) | 1.000 | foto lapangan | uji OOD lapangan | CC BY 4.0 |
| E-Waste *Dataset*, Iliev (Roboflow) | 1.751 (69 kelas) | campuran | uji terkunci | CC BY 4.0 |
| E-waste, Shubha (Roboflow) | 300 (3 kelas dikenal + 2 OOD) | campuran | uji segar | CC BY 4.0 |
| Office-Home (Venkateswara et al., 2017) | 2.917 (20 kelas) | Product vs Real World | uji *domain* lain | riset non-komersial |

Sebanyak 66% citra BDC berukuran paling tinggi 200 piksel. Banyak citra produk Kaan juga kecil dan berlatar putih. Foto objek Bangladesh umumnya sekitar 640 piksel dengan latar beragam, sedangkan foto lapangan GIZ mendekati 1.000 piksel. Perbedaan resolusi dan latar ini dapat mengubah ketetanggaan *embedding* meskipun jenis perangkat sama. Karena itu, evaluasi mengukur konsistensi lintas sumber selain kesesuaian kelompok pada BDC.

### 2.2 Landasan metode

SigLIP2 dan *Perception Encoder* belajar dari hubungan citra dan teks menurut Tschannen et al. (2025) dan Bolya et al. (2025). DINOv3 mempelajari representasi visual tanpa pasangan teks (Siméoni et al., 2025). Ketiga *encoder* citra tetap beku selama eksperimen. Perbandingan representasi tunggal dan fusi menguji apakah tujuan prapelatihan yang berbeda berkaitan dengan ketahanan terhadap sumber foto pada data penelitian ini.

Ciri resolusi, latar, atau pencahayaan dapat menjadi jalan pintas bagi model ketika berkorelasi dengan kelas pada data latih (Geirhos et al., 2020). HEX memakai statistik tekstur GLCM sebagai representasi pembantu lalu memproyeksikan fitur menjauhi subruangnya (Wang et al., 2019). UMFC memperkirakan bias *domain* dari fitur visual dan transisi *domain* teks tanpa label kategori (Liang et al., 2024). Ravfogel et al. (2020) memakai *probe* berulang untuk atribut yang ditentukan melalui INLP. Belrose et al. (2023) menghapus konsep target secara linear melalui LEACE. CMRE memakai residu prediksi *embedding* visi-bahasa dari acuan DINOv3 untuk memilih arah proyeksi. PCA mencari arah dominan pada residu citra utama, lalu proyeksi mengeluarkan arah itu dari *embedding* visi-bahasa. Pemilihan arah ini tidak memerlukan label gaya atau statistik tekstur buatan. Residu dapat pula memuat informasi objek.

*Spectral clustering* mempartisi graf tetangga terdekat melalui vektor eigen Laplacian (Ng et al., 2002). SCMax menggabungkan *clustering* hierarkis dan skor konsensus tetangga untuk memilih jumlah kelompok (Zhang et al., 2026). K keluaran SCMax menjadi input *Spectral clustering* untuk partisi akhir. Hierarki internal SCMax tidak dipakai sebagai taksonomi. Jarak citra baru ke tetangga terdekat pada data utama menjadi skor deteksi di luar distribusi (Sun et al., 2022).

### 2.3 Rancangan metode

Deduplikasi dan ekstraksi *embedding* mendahului proyeksi CMRE. SCMax lalu memilih K pada fitur hasil fusi dan *Spectral* membentuk partisi. Evaluasi memeriksa kelompok dan kategori baru setelah partisi tetap. Label objek hanya dipakai pada tahap tersebut.

Setelah deduplikasi, setiap model menerima citra pada ukuran inputnya dalam orientasi asli dan *horizontal flip*. Kedua *embedding* kemudian dirata-ratakan. SigLIP2-So400m dan PE-Core-G menyediakan representasi visi-bahasa. DINOv3-H+ menjadi acuan visual tanpa supervisi bahasa. Regresi *ridge* memprediksi *embedding* V dari *embedding* DINOv3 S untuk masing-masing model visi-bahasa. Selisih prediksi membentuk residu R (Persamaan 1). PCA mencari arah dominan U_r pada R (Persamaan 2), kemudian proyeksi mengeluarkan arah tersebut dari V (Persamaan 3). Residu dapat memuat informasi objek selain gaya foto. Kami menilai konsekuensi penghapusannya melalui metrik objek dan lintas sumber.

$$(\hat{B}, \hat{b}) = \underset{B,b}{\operatorname{argmin}} \|V - SB - \mathbf{1}b^{\top}\|_F^2 + \alpha\|B\|_F^2 \qquad (1)$$

$$R = V - S\hat{B} - \mathbf{1}\hat{b}^{\top}, \qquad U_r = \mathrm{PCA}_r(R) \tag{2}$$

$$\tilde{v} = \frac{(I - U_r U_r^{\top})v}{\|(I - U_r U_r^{\top})v\|_2} \tag{3}$$

Aturan tanpa label mengambil arah hingga 50% varians residu, dengan batas 64 komponen. Pada data ini r mencapai 64. Regresi *ridge* memakai α = 1. DINOv3-H+ menjadi acuan karena $R^2$ prediksi silang *embedding* VLM mencapai 0,403. DINOv3-7B sedikit lebih tinggi, 0,434, tetapi memerlukan GPU A100. Fusi menggabungkan dua *embedding* hasil CMRE dan *embedding* DINOv3. PCA mereduksinya menjadi 32 dimensi sebelum normalisasi (Persamaan 4). Istilah *erasure* menyebut proyeksi arah residu. *Probe* sumber masih dapat membaca informasi sumber setelah proyeksi.

$$z = \mathrm{PCA}_{32}\left(\left[\tilde{v}_{\mathrm{SigLIP2}};\ \tilde{v}_{\mathrm{PE}};\ s_{\mathrm{DINOv3}}\right]\right) \tag{4}$$

Kami menjalankan SCMax pada *embedding* fusi dengan sembilan *seed* dan memakai median K = 16 untuk partisi akhir. Audit berikutnya mengulang SCMax pada *seed* 0-99 dengan citra dan *embedding* tetap. Untuk setiap K terpilih, *Spectral clustering* membentuk partisi pada graf 15 tetangga, lalu citra eksternal diproyeksikan dengan cara yang sama. Audit ini tidak mengulang ekstraksi fitur atau pengambilan sampel data. Setelah partisi akhir tetap, kami memeriksa citra untuk menamai kelompok dan mengaitkannya dengan kategori WEEE. Kami juga menggabungkan *centroid* dari 16 kelompok memakai *agglomerative average linkage* dan jarak kosinus untuk membaca hubungan antarkelompok. Penggabungan ini tidak mengubah partisi *Spectral* atau K pilihan SCMax. Pusat kelompok terdekat menentukan penempatan citra baru. Jarak ke tetangga ke-10 pada data utama menjadi skor OOD, dengan persentil ke-95 skor data utama sebagai ambang (Persamaan 5). Ekstraksi fitur memakai GPU *cloud* dan *clustering* memakai CPU.

$$s(x) = \left\|z(x) - z_{(10)}(x)\right\|_2 \tag{5}$$

**2.4 Protokol dan metrik evaluasi**

Perbandingan representasi tunggal mengukur bias sumber. Fusi mentah, INLP, LEACE, dan CMRE menguji cara menguranginya. Pada fitur yang sama, kami membandingkan *Spectral* dengan K-Means, Ward, GMM, TEMI, TURTLE, dan protokol DECMCV. Iliev, Shubha, dan Office-Home menguji *transfer* setelah *pipeline* tetap. Perbandingan pada K tetap memakai PCA-32 dan K = 16, sementara audit SCMax memakai K pilihan tiap *seed*. Sapuan r dan jumlah tetangga mengukur kepekaan

parameter. Skor BDC berasal dari proses pengembangan, sehingga tidak diperlakukan sebagai validasi independen.

Penilaian dipisahkan menurut pertanyaan penelitian (Tabel 3). Konsistensi lintas sumber, xsrc (Persamaan 6), dihitung dari lima kelas yang sama pada citra produk Kaan dan foto objek Bangladesh. Untuk setiap kelas c, kelompok mayoritas Kaan menjadi acuan. Proporsi Bangladesh yang masuk kelompok itu dirata-ratakan antarkelas. Nilai xsrc berada antara 0 dan 1, tetapi nilainya juga dapat tinggi bila kelompok terlalu sedikit. Karena itu, perbandingan metode turut menampilkan *Normalized Mutual Information* (NMI) objek pada 1.869 citra eksternal berlabel dari Kaan, Bangladesh, dan Karan serta proporsi citra yang diberi kelompok. AMI pada 2.329 citra BDC berlabel dipakai hanya untuk mengaudit partisi final setelah pilihan metode dibekukan. AMI menyesuaikan kesesuaian *cluster* dan kelas terhadap peluang acak. Nilai 1 berarti identik dan nilai sekitar 0 berarti setara acak (Vinh et al., 2010). Kestabilan dibaca dari Jaccard *bootstrap* per kelompok dan sebaran K antarseed, sedangkan deteksi kategori baru dinilai melalui AUROC dan alarm palsu pada ambang yang telah ditetapkan. Indeks internal seperti *silhouette* dipakai sebagai diagnostik, bukan bukti kesamaan objek lintas sumber.

$$\text{xsrc} = \frac{1}{|\mathcal{C}|}\sum_{c\in\mathcal{C}} \frac{1}{|A_c|}\sum_{i\in A_c} \mathbf{1}\,[y_i = m_c] \tag{6}$$

Tabel 3. Metrik inti sesuai pertanyaan penelitian dan batas interpretasinya

| Metrik | Pertanyaan dan data | Rentang | Makna dan batas |
|---|---|---|---|
| xsrc makro | Kesamaan kelompok lima kelas pada Kaan dan Bangladesh | 0-1, naik | 1: semua kelas cocok dengan kelompok acuan, baca bersama NMI dan cakupan. |
| NMI objek eksternal | Kesesuaian kelompok dengan lima label objek pada 1.869 citra eksternal | 0-1, naik | 1: partisi identik, belum dikoreksi terhadap kecocokan acak. |
| AMI objek BDC | Audit partisi akhir pada 2.329 citra berlabel dalam sepuluh kelas | ≈0 acak, maks. 1 | Nilai negatif mungkin, 1: partisi identik. Tidak dipakai memilih model. |
| Jaccard *bootstrap* | Kestabilan anggota tiap kelompok saat data diambil ulang | 0-1, naik | 1: seluruh anggota pulih, sebaran per kelompok tetap perlu dilaporkan. |
| AUROC OOD dan alarm palsu | Pemisahan kategori baru dari kategori dikenal pada citra eksternal | 0-1 | AUROC 0,5 setara acak, alarm palsu lebih kecil lebih baik pada ambang tetap. |
| Cakupan | Proporsi citra yang memperoleh kelompok | 0-1, naik | 1: seluruh citra ditetapkan, penting bila suatu metode menolak citra. |

## 3. HASIL DAN PEMBAHASAN

### 3.1 Bias sumber pada representasi visual

Dengan protokol yang sama, SigLIP2 dan CLIP menempatkan sekitar 37% foto objek Bangladesh ke kelompok mayoritas citra produk Kaan dari kelas yang sama. DINOv3-H+ mencapai 0,86. MetaCLIP, yang belajar dari pasangan citra-teks, menghasilkan xsrc 0,20 (Xu et al., 2024). Web-DINO tanpa pasangan teks mencapai 0,70 (Fan et al., 2025). Pola tersebut sesuai dengan dugaan bahwa supervisi bahasa dapat memperkuat ciri sumber foto. Arsitektur dan data pelatihan kedua model belum sepenuhnya sepadan, sehingga perbandingan ini belum membuktikan penyebabnya.

Fusi mentah mencapai NMI objek 0,948 pada audit BDC awal, tetapi xsrc hanya 0,524. NMI tersebut memakai 2.331 entri nama berkas sebelum dua entri upload dikeluarkan dari sepuluh kelas objek. Karena itu, angka NMI awal hanya menjadi diagnostik. Skor pada satu sumber tidak menggambarkan perilaku kelompok ketika sumber foto berubah.

### 3.2 Pengaruh CMRE terhadap konsistensi lintas sumber

Pada partisi K = 16, **CMRE menaikkan xsrc fusi dari 0,524 menjadi 0,975**. NMI objek pada data eksternal naik dari 0,789 menjadi 0,859, dan seluruh citra tetap diberi kelompok (Tabel 4). AMI pada 2.329 citra BDC berlabel mencapai 0,917. xsrc per kelas berkisar dari 0,920 untuk baterai hingga 1,000 untuk keyboard dan mouse. Ponsel mencapai 0,981 dan PCB 0,977. INLP dengan proksi gaya juga mencapai xsrc 0,975. Interval selisihnya memuat nol, sehingga uji ini belum membedakan kinerja CMRE dan INLP. LEACE dengan proksi mencapai 0,792. Pada *embedding* CMRE yang sama, TURTLE menghasilkan 0,790, TEMI 0,590, dan protokol DECMCV 0,910. DECMCV hanya mempertahankan 81% citra, sehingga skor itu memiliki cakupan berbeda. Dalam 2.000 *bootstrap* berpasangan, CMRE melampaui fusi mentah dan DINOv3 saja pada BDC, Iliev, dan Shubha ($p < 0,001$). CMRE mencapai hasil tersebut tanpa definisi proksi gaya foto.

Tabel 4. Perbandingan metode pada K = 16 di data pengembangan

| Metode | xsrc | NMI objek ekst. | Cakupan |
|---|---|---|---|
| Fusi mentah | 0,524 | 0,789 | 100% |
| DINOv3-H+ | 0,758 | 0,799 | 100% |

| Metode | xsrc | NMI objek ekst. | Cakupan |
|---|---|---|---|
| TURTLE† | 0,790 | n.d. | 100% |
| TEMI† | 0,590 | n.d. | 100% |
| DECMCV† | 0,910 | n.d. | 81% |
| LEACE×3 | 0,792 | 0,801 | 100% |
| INLP×3 | 0,975 | 0,853 | 100% |
| CMRE cepat | 0,951 | n.d. | 100% |
| CMRE ringan | 0,963 | 0,852 | 100% |
| CMRE usulan | 0,975 | 0,859 | 100% |

xsrc adalah rerata makro lima kelas Kaan-Bangladesh. NMI objek eksternal memakai 1.869 citra dari lima kelas bersama pada Kaan, Bangladesh, dan Karan. Cakupan menunjukkan bagian citra yang tetap diberi kelompok. N.d. berarti NMI belum dihitung dalam arsip pembanding, bukan bernilai nol. Metode bertanda † dijalankan pada *embedding* CMRE yang sama dengan K = 16 dan rerata tiga *seed*. DECMCV membuang citra yang tidak disepakati, sehingga xsrc-nya perlu dibaca bersama cakupan 81%.

*Probe* objek yang dilatih pada citra produk Kaan mencapai akurasi 0,944 pada foto objek Bangladesh sebelum CMRE dan 0,983 sesudahnya. Arah yang dibuang berkorelasi dengan resolusi (|ρ| hingga 0,68) dan proporsi latar putih (0,39). *Probe* sumber masih mencapai 0,96-0,99, sehingga CMRE tidak menghilangkan identitas sumber dari *embedding*. Ketika acuan diganti dengan ConvNeXt V2 berlabel, xsrc turun menjadi 0,384. Pada sembilan pasangan model, besar manfaat CMRE berkaitan dengan jejak gaya awal (Spearman 0,78). Korelasi ini membantu menafsirkan hasil, tetapi belum mengisolasi mekanisme proyeksi.

Pada Iliev, xsrc CMRE mencapai 0,885 (IK95% 0,864-0,908), dibanding 0,803 untuk fusi mentah dan 0,755 untuk DINOv3 saja. *Purity* mencapai 0,939. Kami mengunci pemetaan kelas dan metrik Iliev sebelum mengunduh datanya. Iliev kemudian dipakai memilih skor OOD. Status uji terkunci karena itu hanya berlaku untuk evaluasi *clustering*. Pada 300 *crop* Shubha, CMRE menaikkan xsrc dari 0,356 menjadi 0,956 (IK95% 0,924-0,983). Office-Home menghasilkan pola berbeda. Fusi mentah sudah mencapai xsrc 0,865 dan CMRE memberi 0,864, walaupun *silhouette* naik dari 0,39 menjadi 0,48. Kenaikan xsrc terbesar muncul pada data dengan bias sumber awal yang kuat. Pada Office-Home, CMRE tidak memperbaiki *transfer*.

### 3.3 Pemilihan jumlah kelompok dan sensitivitas parameter

Dalam 100 *seed*, SCMax memilih K = 16 sebagai median dan K = 17 sebagai modus. Sebarannya ialah K = 13 (2 *seed*), 14 (10), 15 (20), 16 (20), 17 (21), 18 (14), 19

(10), 20 (2), dan 21 (1). Partisi final tetap memakai K = 16 dari sembilan *seed* awal. Jika *Spectral* mengikuti K setiap *seed*, rerata xsrc menjadi 0,923 ± 0,098, dengan median 0,975 dan rentang 0,596-0,988. NMI objek eksternal mencapai 0,854 ± 0,022 dan ARI antarpasangan partisi 0,861 ± 0,110. Pada 27 *seed* yang memilih K sedikitnya 18, xsrc berada pada 0,596-0,794. K = 13-17 memberi 0,972-0,988. Variasi ini berasal dari inisialisasi algoritma pada data tetap. *Spectral* membentuk partisi terpisah untuk setiap K, sehingga partisi K = 13 tidak menjadi induk partisi K = 16. Setelah partisi K = 16 tetap, kami menggabungkan *centroid* untuk analisis hierarki. Empat penggabungan pertama memasangkan dua jenis mesin cuci, dua baterai perangkat, dua pemutar audio, dan dua televisi. Keempat cabang muncul pada seluruh 200 *bootstrap* yang mempertahankan anggota *cluster*. Angka itu belum mencakup pengulangan SCMax atau *Spectral* pada sampel baru.

Pada r = 16-64, xsrc berada pada 0,97-0,99. Nilainya turun menjadi 0,449 saat r = 4 dan 0,821 saat r = 128. α = 0,01-1 memberi xsrc 0,975-0,983, sebelum turun pada α yang lebih besar. Dengan K = 16, *Spectral* mencapai xsrc 0,975, K-Means 0,949, GMM 0,926, dan Ward 0,836. K-Means memiliki *silhouette* lebih tinggi daripada *Spectral*, 0,398 berbanding 0,364, meskipun xsrc-nya lebih rendah. Graf dengan 15-30 tetangga memberi xsrc 0,975-0,988. Pada 5-10 tetangga, nilainya sekitar 0,91. Empat *seed Spectral* tambahan pada K = 16 menghasilkan ARI 1,00 terhadap partisi final. Pemeriksaan ini tidak memasukkan variasi K dari SCMax. Sebelas dari 16 kelompok mencapai Jaccard *bootstrap* sedikitnya 0,85.

### 3.4 Penafsiran kelompok dan batas taksonomi

Tabel 5 merinci isi dominan, jumlah citra, kestabilan, dan kemungkinan penanganan keenam belas kelompok. Kami memberi nama kelompok setelah memeriksa citranya. Kategori WEEE dan B3 juga ditautkan setelah partisi selesai. Model tidak memakai nama atau kategori tersebut saat membentuk kelompok.

Tabel 5. Interpretasi kelompok dan implikasi penanganannya

| C | Isi kelompok | n | Kategori WEEE / B3 | Jaccard | Implikasi penanganan |
|---|---|---|---|---|---|
| 0 | Aki timbal-asam | 115 | baterai (B3) | 0,71 | timbal dan asam sulfat, daur ulang aki khusus |
| 1 | Baterai pack laptop | 70 | baterai Li-ion | 0,94 | risiko kebakaran, lepas sebelum pencacahan |
| 2 | Turntable | 111 | 5 (Small equipment) | 0,96 | pembongkaran umum |

| C | Isi kelompok | n | Kategori WEEE / B3 | Jaccard | Implikasi penanganan |
|---|---|---|---|---|---|
| 3 | TV/monitor CRT | 174 | 2 (Screens & monitors) | 0,79 | kaca bertimbal, perlakuan selektif |
| 4 | Baterai ponsel/kamera | 136 | baterai Li-ion kecil | 0,82 | titik kumpul baterai |
| 5 | Pemutar CD/radio | 153 | 5 (Small equipment) | 0,97 | pembongkaran umum |
| 6 | Mesin cuci bukaan atas | 115 | 4 (Large equipment) | 0,98 | logam dan motor |
| 7 | TV/monitor layar datar | 263 | 2 (Screens & monitors) | 0,85 | lampu latar lama dapat mengandung merkuri |
| 8 | Mesin cuci front-load | 192 | 4 (Large equipment) | 0,99 | logam dan motor |
| 9 | Laptop | 277 | 2 (Screens & monitors) | 0,98 | baterai, layar, dan PCB bernilai |
| 10 | Keyboard | 320 | 6 (Small IT & Telecom) | 0,90 | plastik dominan |
| 11 | Microwave | 275 | 5 (Small equipment) | 1,00 | kapasitor tegangan tinggi |
| 12 | Printer | 294 | 6 (Small IT & Telecom) | 1,00 | kartrid toner |
| 13 | Mouse | 291 | 6 (Small IT & Telecom) | 1,00 | plastik dominan |
| 14 | Ponsel | 366 | 6 (Small IT & Telecom) | 0,94 | baterai dan PCB bernilai |
| 15 | PCB dan tumpukan campuran | 640 | komponen | 0,85 | logam mulia, perlu pra-pemilahan |

Empat penggabungan awal pada hierarki *centroid* mempertemukan mesin cuci bukaan atas dan depan, baterai laptop dan baterai kecil, dua jenis pemutar audio, serta TV CRT dan layar datar. Potongan 12 kelompok mempertahankan *purity* BDC 0,993 pada 2.329 citra berlabel dan xsrc 0,975. Ketika jumlah kelompok turun ke delapan, *purity* menjadi 0,796 karena kategori perangkat berbeda mulai bergabung. Hierarki berguna untuk merangkum penggabungan awal, sedangkan cabang atas belum dapat ditafsirkan sebagai taksonomi penanganan. C9 didominasi laptop walaupun nama berkas BDC mengaitkannya dengan keyboard. Sebanyak 96,7% foto laptop Iliev masuk ke C9. Pada citra Iliev yang dikenali, 79% penempatan kelompok sesuai kategori EU-6. Angka itu 19% pada 100.000 penggabungan acak dengan ukuran grup sama ($p < 0,001$). Jarak antarpusat kelompok dalam satu kategori WEEE tidak lebih kecil dari acak ($p = 0,46$). Karena itu, kategori WEEE dipakai untuk interpretasi setelah *clustering*.

Dari 449 foto objek Bangladesh pada lima kelas bersama, 12 gagal masuk kelompok mayoritas citra produk Kaan. Tujuh baterai masuk kelompok aki, tiga PCB masuk baterai ponsel, dan dua ponsel masuk baterai. Beberapa stop kontak masuk C0 bersama objek berbentuk kotak dengan terminal logam. Foto tumpukan campuran terkumpul pada C15 bersama papan sirkuit. Kelompok aki, CRT, dan baterai kecil memiliki Jaccard *bootstrap* 0,71-0,82, di bawah kelompok lain. Kesalahan tersebut tetap perlu diperiksa walaupun kemurnian agregat tinggi.

### 3.5 Deteksi perangkat di luar kategori

Pada Iliev, skor jarak tetangga terdekat mencapai AUROC OOD 0,937. Skor jarak ke pusat kelompok mencapai 0,868. Kami memilih skor pertama memakai Iliev, sehingga angka ini merupakan hasil pengembangan OOD. Pada Shubha, AUROC mencapai 0,994 (IK95% 0,984-0,999) dengan dua kelas baru yang tersedia. Ambang persentil ke-95 menandai 94% foto lampu Bangladesh yang tidak terwakili di BDC, tetapi juga salah menandai 13% foto Bangladesh dari kelas dikenal. Pada Iliev, alarm muncul pada 97% foto AC, 83% kulkas, dan seluruh foto setrika, kipas angin, lampu LED, serta dispenser air. Pemutar MP3 portabel juga sering memicu alarm karena kelompok pemutar BDC didominasi perangkat lebih besar.

Ambang OOD menandai 44,5% foto lapangan GIZ. Foto yang ditandai mencakup banyak AC, kulkas, dan kompresor yang tidak terwakili dalam kelompok utama BDC. Persentase tersebut belum mengukur akurasi karena label GIZ tidak lengkap. Petugas perlu memeriksa foto beralarm sebelum menentukan jalur penanganan.

### 3.6 Hubungan dengan studi terdahulu dan penggunaan di Indonesia

Huang et al. (2025) melaporkan gangguan gaya foto pada DECMCV. CMRE menguji proyeksi residu untuk mengurangi gangguan tersebut tanpa membuang citra, lalu xsrc mengukur apakah perangkat sejenis tetap satu kelompok saat sumber foto berubah. Islam et al. (2023) menilai klasifikasi pada kategori yang telah ditentukan. Penelitian ini membentuk kelompok sebelum memakai label, sehingga akurasi klasifikasi mereka tidak sepadan dengan xsrc. Zhou et al. (2025) mengaitkan tipe produk dengan kebutuhan pembongkaran. Kelompok yang memisahkan subtipe perangkat di sini masih memerlukan penilaian ahli sebelum menjadi dasar penanganan.

Alat bantu triase foto untuk bank sampah dapat menampilkan kelompok perkiraan, skor OOD, dan pilihan pemeriksaan manual. Foto beralarm memerlukan keputusan petugas. Versi cepat SigLIP2 dan DINOv3 memproses sekitar 20 citra per detik pada GPU L4, dibanding 3,4 untuk *pipeline* penuh. xsrc versi cepat mencapai 0,951 pada BDC, 0,860 pada Iliev, dan 0,922 pada Shubha. Kecepatan tersebut belum diukur pada ponsel. Penerapan di Indonesia masih memerlukan foto rumah tangga setempat dan pemeriksaan jalur penanganan oleh petugas.

### 3.7 Keterbatasan

Kami memakai BDC untuk memilih lebih dari 40 varian. Karena itu, xsrc BDC 0,975 cenderung optimistis. Protokol *clustering* Iliev dikunci sebelum data diunduh, sedangkan Shubha hanya berisi 300 *crop*. Data belum memuat foto langsung dari rumah tangga atau bank sampah Indonesia. Selisih CMRE terhadap INLP pada metrik utama belum signifikan. Ketika DINOv3-H+ diganti DINOv3-B, xsrc turun menjadi 0,593. *Probe* masih dapat mengenali sumber foto setelah CMRE. Dalam audit 100 *seed*, SCMax memilih K antara 13 dan 21. Sebanyak 27 *seed* dengan K sedikitnya 18 menghasilkan xsrc paling tinggi 0,794. Audit ini memakai *embedding* tetap. *Bootstrap* hierarki juga mempertahankan anggota *cluster*, sehingga keduanya belum mengukur variasi seluruh *pipeline* pada sampel baru. Hasil hitung ulang v4 sedikit berbeda dari artefak tersimpan dan penyebab perbedaan fitur belum terisolasi. Ambang OOD global salah menandai 13% foto Bangladesh dari kelas dikenal. Pemutar MP3 dan TV Iliev juga tidak selalu sepadan dengan definisi kelas BDC.

## 4. PENUTUP

SigLIP2 dan CLIP memberi xsrc sekitar 0,37 pada audit awal, sedangkan DINOv3-H+ mencapai 0,86. Pada fusi tiga *encoder*, **CMRE menaikkan xsrc BDC dari 0,524 menjadi 0,975** dan menghasilkan AMI 0,917 pada sepuluh kelas berlabel. **xsrc Iliev naik dari 0,803 menjadi 0,885 dan Shubha dari 0,356 menjadi 0,956**. Office-Home tetap sekitar 0,865. Kenaikan terbesar muncul pada data dengan bias sumber awal yang kuat. Sembilan *seed* awal memberi median K = 16. Audit 100 *seed* mempertahankan median itu, tetapi **ARI antarpasangan partisi hanya 0,861**. Enam belas kelompok akhir memisahkan beberapa subtipe perangkat. Penggabungan *centroid* menjelaskan pasangan awal, sedangkan cabang atas belum mengikuti kategori penanganan. Skor OOD kNN mencapai AUROC 0,994 pada Shubha yang memiliki dua kelas baru, sambil salah menandai 13% foto Bangladesh dari kelas dikenal. Hasil ini mendukung pemakaian kelompok sebagai bahan pemeriksaan foto oleh petugas. Evaluasi belum mencakup foto rumah tangga Indonesia.

Pengujian lanjutan perlu mengumpulkan foto rumah tangga dan bank sampah Indonesia, terutama perangkat penukar suhu dan tumpukan campuran. Pemetaan kategori harus ditetapkan sebelum foto itu dinilai. Ablasi perlu memisahkan kontribusi regresi,

proyeksi residu, dan pilihan model acuan. Untuk menilai kestabilan K, seluruh *pipeline* perlu diulang pada sampel citra baru. Kalibrasi ambang OOD per kelompok memerlukan data pengembangan terpisah. Versi cepat SigLIP2 dan DINOv3 juga perlu diuji latensinya pada perangkat sasaran sebelum dipakai di lapangan.

**REFERENSI**


Adaloglou, N., Michels, F., Kalisch, H., & Kollmann, M. (2023). Exploring the limits of deep image clustering using pretrained models. *Proceedings of the British Machine Vision Conference (BMVC)*.

Baldé, C. P., Kuehr, R., Yamamoto, T., et al. (2024). *The global e-waste monitor 2024*. International Telecommunication Union & United Nations Institute for Training and Research. https://ewastemonitor.info

Belrose, N., Schneider-Joseph, D., Ravfogel, S., Cotterell, R., Raff, E., & Biderman, S. (2023). LEACE: Perfect linear concept erasure in closed form. *Advances in Neural Information Processing Systems, 36*.

Bolya, D., et al. (2025). Perception Encoder: The best visual embeddings are not at the output of the network. *arXiv:2504.13181*.

Defitri, M. (2022, 12 Oktober). *Pengelolaan sampah elektronik dan peraturannya di Indonesia*. Waste4Change. https://waste4change.com/blog/pengelolaan-sampah-elektronik-dan-peraturannya-di-indonesia/

European Parliament and Council. (2012). Directive 2012/19/EU on waste electrical and electronic equipment (WEEE). *Official Journal of the European Union, L 197*.

Fan, D., et al. (2025). Scaling language-free visual representation learning. *arXiv:2504.01017*.

Gadetsky, A., Jiang, Y., & Brbić, M. (2024). Let go of your labels with unsupervised transfer. *Proceedings of the 41st International Conference on Machine Learning (ICML)*.

Geirhos, R., Jacobsen, J.-H., Michaelis, C., Zemel, R., Brendel, W., Bethge, M., & Wichmann, F. A. (2020). Shortcut learning in deep neural networks. *Nature Machine Intelligence, 2*(11), 665-673.

Gundupalli, S. P., Hait, S., & Thakur, A. (2018). Classification of metallic and non-metallic fractions of e-waste using thermal imaging-based technique. *Process Safety and Environmental Protection*. https://www.sciencedirect.com/science/article/abs/pii/S0957582018303434

Hennig, C. (2007). Cluster-wise assessment of cluster stability. *Computational Statistics & Data Analysis, 52*(1), 258-271.

Huang, K., Song, M., Ba, S., An, L., Liang, H., Deng, H., Liu, Y., Zhang, Z., & Zhou, C. (2025). Unsupervised waste classification by dual-encoder contrastive learning and multi-clustering voting (DECMCV). *arXiv:2503.02241*.

Islam, N., Jony, M. M. H., Hasan, E., Sutradhar, S., Rahman, A., & Islam, M. M. (2023). EWasteNet: A two-stream data efficient image transformer approach for e-waste classification. *arXiv:2311.12823*.

Jano, T., et al. (2026). Closing the loop: A systematic review of artificial intelligence in circular e-waste management. *Waste Management, 214*, 115392.

Liang, J., Hou, R., Hu, M., Chang, H., Shan, S., & Chen, X. (2024). UMFC: Unsupervised multi-domain feature calibration for vision-language models. *Advances in Neural Information Processing Systems, 37*. https://doi.org/10.52202/079017-3623

Ng, A. Y., Jordan, M. I., & Weiss, Y. (2002). On spectral clustering: Analysis and an algorithm. *Advances in Neural Information Processing Systems, 14*.

Pemerintah Republik Indonesia. (2020). *Peraturan Pemerintah Nomor 27 Tahun 2020 tentang Pengelolaan Sampah Spesifik*.

Rajeev, P. A., Dharewa, V., Lakshmi, D., et al. (2025). Advancing e-waste classification with customizable YOLO based deep learning models. *Scientific Reports, 15*, 18151. https://doi.org/10.1038/s41598-025-94772-x

Ravfogel, S., Elazar, Y., Gonen, H., Twiton, M., & Goldberg, Y. (2020). Null it out: Guarding protected attributes by iterative nullspace projection. *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*, 7237-7256.

Siméoni, O., et al. (2025). DINOv3. *arXiv:2508.10104*.

Sun, Y., Ming, Y., Zhu, X., & Li, Y. (2022). Out-of-distribution detection with deep nearest neighbors. *Proceedings of the 39th International Conference on Machine Learning (ICML)*, 20827-20840.

Tschannen, M., et al. (2025). SigLIP 2: Multilingual vision-language encoders with improved semantic understanding, localization, and dense features. *arXiv:2502.14786*.

Venkateswara, H., Eusebio, J., Chakraborty, S., & Panchanathan, S. (2017). Deep hashing network for unsupervised domain adaptation. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 5018-5027.

Vinh, N. X., Epps, J., & Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. Journal of Machine Learning Research, 11, 2837-2854. https://jmlr.org/papers/v11/vinh10a.html

Wang, H., He, Z., Lipton, Z. C., & Xing, E. P. (2019). Learning robust representations by projecting superficial statistics out. *International Conference on Learning Representations (ICLR)*. https://arxiv.org/abs/1903.06256

Xu, H., et al. (2024). Demystifying CLIP data. *Proceedings of the International Conference on Learning Representations (ICLR)*.

Yalavarthi, B. C., Ratha, N., & Govindaraju, V. (2026). Label-free mitigation of spurious correlations in VLMs using sparse autoencoders. *International Conference on Learning Representations (ICLR)*.

Zhang, L., Liu, S., Wang, S., Yu, S., Zhu, X., Li, M., & Liu, X. (2026). Parameter-free clustering via self-supervised consensus maximization. *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI-26)*.

Zhou, C., Sterkens, W., Díaz-Romero, D. J., Zaplana, I., & Peeters, J. (2023). You only demanufacture once (YODO): WEEE retrieval using unsupervised learning. *Resources, Conservation & Recycling, 190*, 106826.

Zhou, C., Wu, Y., Sterkens, W., Vandewalle, P., Zhang, J., & Peeters, J. R. (2025). Multi-view graph transformer for WEEE classification and retrieval. *Resources, Conservation & Recycling, 215*, 108112.

**Sumber data tambahan:** Kaan Erkez, Waste Classification Dataset (https://www.kaggle.com/datasets/kaanerkez/waste-classfication-dataset), Custom Bangladeshi E-Waste (https://data.mendeley.com/datasets/77383kmdnw/1), Karan Solanki, Garbage Classification (https://www.kaggle.com/datasets/karansolanki01/garbage-classification), GIZ, E-Waste Database (https://huggingface.co/datasets/GIZ/E-Waste-Database), Electronic Waste Detection (Iliev), E-Waste Dataset (https://universe.roboflow.com/electronic-waste-detection/e-waste-dataset-r0ojc), Shubha, E-waste Dataset (https://universe.roboflow.com/shubha-to6ii/e-waste-1sn3k), Office-Home (https://huggingface.co/datasets/flwrlabs/office-home).

## LAMPIRAN

Kode reproduksi untuk ekstraksi fitur, *clustering*, dan evaluasi tersedia di https://github.com/elzaff/cross-model-residual-*erasure-clustering*-bdc-ewaste. Cuplikan berikut memperlihatkan operasi inti.

```
import numpy as np
from sklearn.cluster import SpectralClustering
from sklearn.decomposition import PCA
from sklearn.linear_model import Ridge
from sklearn.neighbors import NearestNeighbors
def l2(x):
    return x / (np.linalg.norm(x, axis=1, keepdims=True) + 1e-8)
def cmre(v, ref, r=64, alpha=1.0):
    """Cross-Model Residual Erasure: remove from the VLM embeddings v the top-r principal
directions of the part
    that the self-supervised reference cannot predict. Returns the cleaned embeddings and the
projector P,
    which is applied unchanged to new images (v_new @ P)."""
    residual = v - Ridge(alpha=alpha).fit(ref, v).predict(ref)          # Eq. 1-2
    U = PCA(r, random_state=0).fit(residual).components_                 # top-r residual
directions
    P = np.eye(v.shape[1], dtype=v.dtype) - U.T @ U
    return l2(v @ P), P                                                  # Eq. 3
def fuse(parts, dim=32):
    """Concatenate the cleaned embeddings, reduce with PCA and re-normalise (Eq. 4)."""
    x = l2(np.hstack(parts))
    pca = PCA(dim, random_state=0).fit(x)
    return l2(pca.transform(x)), pca
def cluster(z, k=16, n_neighbors=15, seed=0):
    """Spectral clustering on a k-nearest-neighbour graph, k = median SCMax choice over 9
seeds."""
    return SpectralClustering(k, affinity="nearest_neighbors", n_neighbors=n_neighbors,
                              random_state=seed, assign_labels="cluster_qr").fit_predict(z)
class KnnOOD:
    """kNN out-of-distribution detector (Sun et al., 2022): distance to the k-th nearest D_main
image (Eq. 5),
    an image is 'unknown' above the q-th percentile of the D_main scores (leave-one-out)."""
    def __init__(self, z_main, k=10, q=95):
        self.k = k
        self.nn = NearestNeighbors(n_neighbors=k + 1).fit(z_main)
        self.threshold = np.percentile(self.nn.kneighbors(z_main)[0][:, k], q)
    def score(self, z):
        return self.nn.kneighbors(z, self.k)[0][:, -1]
    def is_unknown(self, z):
        return self.score(z) > self.threshold
def run(sig, pe, dino, k=16):
    """Full pipeline on D_main: returns the fused features, cluster labels and the OOD
detector."""
    sig_clean, _ = cmre(sig, dino)
    pe_clean, _ = cmre(pe, dino)
    z, _ = fuse([sig_clean, pe_clean, dino])
    return z, cluster(z, k), KnnOOD(z)
```

Tabel 6. CMRE dengan model acuan berbeda (BDC, K = 16), diurutkan menurut $R^2$ *ridge* tanpa label

| Model acuan | Jenis | $R^2$ *ridge* | xsrc mentah | xsrc CMRE |
|---|---|---|---|---|
| DINOv3-7B | SSL | 0,434 | 0,568 | 0,983 |
| **DINOv3-H+ (usulan)** | SSL | 0,403 | 0,524 | **0,975** |
| ConvNeXt V2-H | berlabel | 0,392 | 0,480 | 0,384 |
| DINOv3-L | SSL | 0,390 | 0,550 | 0,596 |
| Web-DINO-1B | SSL | 0,382 | 0,550 | 0,917 |
| Web-DINO-300M | SSL | 0,358 | 0,591 | 0,930 |
| DINOv2-L | SSL | 0,351 | 0,516 | 0,777 |
| DINOv3-B | SSL | 0,347 | 0,481 | 0,593 |
| DINOv3-ConvNeXt-L | SSL | 0,345 | 0,593 | 0,726 |

$R^2$ *ridge*: kemampuan acuan memprediksi *embedding* VLM (validasi silang 5 lipatan, tanpa label). Korelasi peringkat $R^2$ dengan xsrc pada delapan acuan SSL = 0,69. Acuan berlabel dikecualikan secara prinsip.

Tabel 7. Uji *bootstrap* berpasangan: selisih xsrc usulan dikurangi pembanding [IK95%], 2.000 ulangan

| Pembanding | BDC | Iliev | Shubha |
|---|---|---|---|
| Fusi mentah | +0,451 [0,429–0,476] | +0,082 [0,057–0,106] | +0,600 [0,559–0,637] |
| DINOv3-H+ saja | +0,217 [0,188–0,244] | +0,130 [0,113–0,149] | +0,067 [0,034–0,105] |
| INLP ×3 (butuh proksi) | −0,008 [−0,021–0,005] | +0,003 [−0,017–0,023] | −0,017 [−0,037–0,000] |
| Versi ringan PE + DINOv3 | +0,006 [−0,010–0,021] | +0,003 [−0,008–0,017] | +0,011 [0,000–0,029] |
| Versi cepat SigLIP2 + DINOv3 | +0,024 [0,005–0,047] | +0,025 [0,009–0,043] | +0,033 [0,011–0,061] |

Nilai positif berarti usulan lebih tinggi. Selisih terhadap INLP dan versi ringan tidak signifikan (interval memuat nol).

## Catatan reproduksi v4

Audit 100 *seed* SCMax menggunakan *embedding* dan citra yang tetap. Median K = 16, tetapi hanya 20 *seed* memilih tepat K = 16. Sebanyak 27 *seed* memilih K sedikitnya 18 dan menghasilkan xsrc paling tinggi 0,794. Rerata ARI antarpasangan partisi adalah 0,861. Sebaran ini menunjukkan kepekaan algoritmik terhadap *seed*, bukan interval kepercayaan akibat pengambilan sampel. *Bootstrap* berpasangan 2.000 kali mengambil ulang citra evaluasi per kelas tanpa mengulang ekstraksi *embedding*, CMRE, PCA, atau pemilihan K. Hitung ulang v4 menghasilkan xsrc BDC 0,970011, sedangkan artefak tersimpan mencatat 0,975411. Partisi 3.792 citra utama identik (ARI 1,000), sementara enam dari 3.773 citra luar berubah penempatan *centroid*. Penyebab teknis selisih fitur kecil ini belum terisolasi. Metadata lama mencatat r = 65 dari indeks ambang varians, tetapi PCA hanya menghitung 64 komponen. Jumlah arah yang diproyeksikan adalah 64. Audit ini belum mengukur variasi dari ekstraksi ulang, pengambilan sampel baru, atau pemilihan model.